UNIWERSYTET
EKONOMICZNY
W POZNANIU

Szymon Płaziak

Wykorzystanie NLP w predykcji sukcesu finansowego filmów

Use of NLP in movie boxoffice prediction

Praca licencjacka

Promotor: dr hab. Krzysztof Węcel, prof. UEP

Kierunek: Informatyka i ekonometria

Specjalność: Informatyka w gospodarce i administracji

Poznań 2025

Spis treści

1 Wstęp **1**

1.1 Motywacja 1

1.2 Cele pracy 2

1.3 Metodyka badawcza 2

1.4 Struktura pracy 4

2 Podstawowe założenia dotyczące przetwarzania języka naturalnego **5**

2.1 Proces zrozumienia języka naturalnego 5

2.2 Narzędzia i techniki stosowane w NLP 7

2.3 Zastosowania NLP 8

2.4 Porównanie nowego i klasycznego podejścia 10

2.5 Modele wstępnie wytrenowanie 11

2.6 Tworzenie wektorów właściwościowych 12

2.7 Wykorzystanie uczenia nienadzorowanego i nadzorowanego 13

2.8 Przegląd aktualnego stanu technologii 14

2.9 Podsumowanie 17

3 Metodyka badawcza **19**

3.1 Problem badawczy 20

3.2 Hipoteza badawcza 20

3.3 Cel i zakres badania 21

3.4 Planowane podejście metodologiczne 22

4 Przygotowanie danych **24**

4.1 Zbieranie danych 24

4.2 Przetwarzanie i czyszczenie danych 27

4.3 Analiza i przetwarzanie zmiennych tekstowych 36
4.4 Zakodowanie zmiennych kategorycznych 38

5 Tworzenie i weryfikacja modeli 42
5.1 Generowanie wektorów właściwościowych 42
5.2 Modele klasyczne 46
5.3 Modele wzbogacone o wektory właściwościowe 51
5.4 Wnioski 55

6 Podsumowanie 57

Rozdział 1

Wstęp

Prognozowanie przychodów z dystrybucji filmów od lat stanowi interdyscyplinarne wyzwanie, które łączy elementy informatyki, ekonometrii i zarządzania. Tradycyjne modele, oparte przede wszystkim na zmiennych liczbowych, takich jak budżet produkcji, koszty marketingu, termin premiery czy popularność obsady, wykazują jednak ograniczoną skuteczność. Wynika to z dwóch głównych przyczyn. Po pierwsze, relacje pomiędzy cechami stanowiącymi o sukcesie produkcji, a wynikami finansowymi często przybierają formę nieliniowych zależności, których proste, liniowe metody nie modelują w sposób wystarczający. Z kolei modele hierarchiczne lub grafowe, które oferują rozwiązania problemów wynikających z nieliniowości, wciąż na ogół są ograniczone do strukturyzowanych metadanych filmów. Po drugie, w związku z rosnąca dostępnością niestrukturyzowanych danych, czyli opisów fabuły, streszczeń czy list słów kluczowych, stawia przed badaczami pytanie o ich dotychczas niewykorzystany potencjał w zastosowaniach predykcyjnych, szczególnie idącym w parze z gwałtownym rozwojem technik uczenia maszynowego.

1.1 Motywacja

Postęp w dziedzinie przetwarzania języka naturalnego (NLP) i uczenia maszynowego otworzył nowe możliwości wykorzystania tych zasobów. Nowoczesne techniki NLP potrafią przedstawiać tekst w postaci gęstych wektorów zachowujących niuanse semantyczne oraz kontekstowe. Dzięki temu cechy tekstowe mogą ujawniać schematy gatunkowe, motywy narracyjne czy sentyment, czyli aspekty wychodzące poza spektrum możliwości w klasycznych zmiennych liczbowych. Wstępne badania pokazują, że połączenie

informacji liczbowych i tekstowych pozwala obniżyć błąd przewidywań, w niektórych nawet o kilkadziesiąt procent. Dodatkowo, popularność rozwiązań, takich jak chatboty AI czy implementacja LLM w procesach biznesowych, podkreśla znaczenie NLP w analityce danych i innowacyjnością przedsiębiorstw. Z perspektywy praktycznej, dotyczącej poruszanego tematu niniejszej pracy, lepsze prognozy wspierają decyzje inwestorów, producentów i dystrybutorów, ograniczając ryzyko finansowe związane z wysoko kosztowymi produkcjami filmowymi.

1.2 Cele pracy

Głównym celem pracy jest przeprowadzenie eksperymentu porównującego skuteczność dwóch podejść do prognozowania sukcesu finansowego filmów. Pierwsze z nich, modele operujące wyłącznie na danych liczbowych, zarówno klasyczne jak i z wykorzystaniem technik uczenia maszynowego. Drugie, modele wykorzystujące dodatkowo reprezentacje tekstowe pozyskiwane z opisów fabuły i słów kluczowych. Badanie koncentruje się na produkcjach amerykańskich z lat 2014–2023, a zmienną objaśnianą jest logarytm ilorazu przychodu do budżetu. Tak zdefiniowana zmienna redukuje wpływ obserwacji odstających i przybliża jej rozkład do normalnego, co sprzyja stosowaniu klasycznych technik statystycznych.

Hipoteza badawcza zakłada, że modele łączące cechy liczbowe i wektorowe reprezentacje tekstu osiągną statystycznie istotnie lepsze wyniki niż modele bazujące wyłącznie na danych liczbowych. W praktyce oznacza to polepszenie wartości miar dobroci modelu w zadaniach regresji i klasyfikacji. Odpowiedź na to pytanie pozwoli ocenić, czy opisy fabuł i słowa kluczowe stanowią realny czynnik predykcyjny, który może uzupełnić dotychczasowe parametry ilościowe.

1.3 Metodyka badawcza

Na potrzeby eksperymentu zebrano, a następnie przygotowano zbiór danych obejmujący filmy z bazy The Movie Database (TMDB). Dane pozyskano poprzez zapytania API do TMDB, a następnie odfiltrowano pod kątem produkcji amerykańskich i anglojęzycznych. Po wstępnej inspekcji zdecydowano się na przedział lat 2014–2023, który gwarantował

największą kompletność metadanych. Dane liczbowe, takie jak budżet, przychód, czas trwania i termin premiery, poddano transformacji logarytmicznej tam, gdzie było to konieczne.

Zanim zmienne tekstowe zostały modelowane, przeszły przez wstępną obróbkę. Po upewnieniu się, że są one po angielsku, nie zawierają żadnych znaków specjalnych i artefaktów występujących po pobraniu ich z bazy, zostały poddane standaryzacji umożliwiającej dalsze modelowanie. W przypadku słów kluczowych oznacza to analizę występowania, ich kompletności oraz częstości dla każdego filmu, a następnie ustaleniu progów istotności występowania słów dla każdego z filmów i usunięcia rekordów mogących wprowadzać szum przy treningu modeli.

Następnym krokiem było zakodowanie kolumn kategorii gatunków i najistotniejszych słów kluczowych techniką one-hot, a dla podmiotów zaangażowanych w produkcję filmu wprowadzono binarne zmienne na podstawie rankingów, wyznaczonych za pomocą ich popularności.

Kolejnym krokiem podczas obróbki danych jakościowych było wygenerowanie wektorów właściwościowych przy użyciu modelu Qwen3 Embedding. Uśredniono wektory słów kluczowych, a następnie scalono z wektorami wygenerowanymi na podstawie opisów. Uzyskane reprezentacje zredukowano do 200 komponentów, co pozwoliło zachować ok. 85% wariancji przy jednoczesnym ograniczeniu nad wymiarowości zbioru danych oraz uniknięcia ryzyka przeuczenia.

Na tak przygotowanych danych zbudowano dwa zestawy modeli. Grupa klasycznych obejmuje regresję liniową, lasy losowe, które służą za punkt odniesienia, oraz algorytmu uczenia maszynowego opartego na gradient boosting - XGBoost. Grupa modeli rozszerzonych o wektory właściwościowe wykorzystuje jedynie modele oparte na XGBoost, ze względu na oczywisty brak skuteczności algorytmów klasycznych przy wykorzystaniu dodanych wektorów. Optymalizację hiperparametrów przeprowadzono z użyciem walidacji krzyżowej i wyszukiwania Bayesian optimization. Skuteczność oceniano zestawem metryk regresyjnych i klasyfikacyjnych. W celu interpretacji znaczenia poszczególnych zmiennych zastosowano analizę SHAP, co umożliwiło identyfikację komponentów o największym wpływie na wyniki.

1.4 Struktura pracy

Rozdział drugi, za pomocą przeglądu literatury i aktualnego stanu wiedzy, przybliża podstawowe pojęcia NLP, ze szczególnym uwzględnieniem sposobów reprezentowania tekstu i ich roli w zadaniach predykcyjnych. Rozdział trzeci rozwija metodykę badawczą, gdzie sprecyzowane zostają zagadnienia problemu badawczego, hipotezy badawczej i przyjętych metod analitycznych. Rozdział czwarty dokumentuje proces przygotowania danych, od pobrania rekordów, przez czyszczenie po kodowanie zmiennych kategorycznych. W rozdziale piątym zaprezentowano generowanie wektorów właściwościowych, konstrukcję modeli, parametry ich treningu oraz szczegółową analizę wyników, konfrontując modele klasyczne z rozszerzonymi. Ostatni, szósty rozdział podsumowuje wnioski, odnosi je do pierwotnej hipotezy oraz wskazuje możliwości dalszych badań nad wykorzystaniem reprezentacji tekstowych w prognozowaniu sukcesu finansowego filmów.

W niniejszej pracy została wykorzystana generatywna sztuczna inteligencja, służyła ona jedynie przy obróbce stylizacyjnej tekstu i utrzymania poprawności językowej. Wszystkie opisanie koncepty i podejścia metodologiczne zostały sformułowane i opracowane przeze mnie.

Rozdział 2

Podstawowe założenia dotyczące przetwarzania języka naturalnego

Techniki przetwarzania języka naturalnego (ang. Natural Language Processing, NLP) zajmują się badaniem języka stosowanego przez ludzi w codziennej komunikacji, zarówno mówionej, jak i pisanej. Ich celem jest zrozumienie i usystematyzowanie informacji zawartej w tekście. NLP jako dziedzina interdyscyplinarna łączy lingwistykę, informatykę, matematykę, psychologię oraz w ostatnich latach najważniejszy zakres dotyczący sztucznej inteligencji. Założeniem NLP jest opracowanie narzędzi, które umożliwiają efektywną interpretacje tekstu tworzonego przez ludzi poprzez programy komputerowe (Chowdhary, 2020, s. 51).

2.1 Proces zrozumienia języka naturalnego

Proces zrozumienia języka naturalnego polega na zastosowaniu różnych technik NLP, które obejmują kilka poziomów analizy i umożliwiają przetwarzanie danych tekstowych oraz mówionych przez komputer. Pierwszy z nich, poziom fonetyczny i fonologiczny, dotyczy analizy wymowy oraz dźwięków w języku mówionym, co jest szczególnie istotne w rozpoznawaniu mowy poprzez identyfikację i przyporządkowanie poszczególnych dźwięków (Chowdhary, 2020, s. 4). Współczesne systemy rozpoznawania mowy, wykorzystywane na przykład w systemach dialogowych, wykorzystują głębokie sieci neuronowe do odwzorowania sygnałów akustycznych na tekst, co znacząco podniosło skuteczność tego etapu (Hirschberg i Manning, 2015, s. 261).

Następnie na poziomie morfologicznym bada się najmniejsze jednostki językowe dające znaczenie zdaniom, takie jak morfemy, przedrostki czy przyrostki, co pozwala rozpoznać strukturę słów i ich odmian (Chowdhary, 2020, s. 5). W tym zakresie istotne okazują się także podejścia oparte na analizie pod słów, wykorzystującej reprezentacje wektorowe znaków i fragmentów słów, szczególnie przydatne w językach o rozbudowanej morfologii (Goldberg, 2016, s. 349).

Kolejnym obszarem jest poziom leksykalny, który obejmuje analizę słów, ich znaczeń oraz przypisywanie ich do części mowy w oparciu o słowniki i bazy wiedzy. Systemy, takie jak Stanford CoreNLP, realizują ten etap automatycznie, oznaczając każdemu słowu odpowiednią kategorię gramatyczną, co umożliwia dalsze przetwarzanie tekstu (Hirschberg i Manning, 2015, s. 262).

Dalej występuje poziom syntaktyczny, pozwalający na analizę struktury gramatycznej zdań poprzez identyfikację związków między słowami, co służy do tworzenia poprawnych gramatycznie tekstów lub tłumaczeń maszynowych. Przykładowo, rekurencyjne sieci neuronowe są wykorzystywane do analizowania struktur drzewiastych zdań, co pozwala na ujęcie hierarchii składniowej w sposób bardziej zbliżony do ludzkiego przetwarzania języka (Goldberg, 2016, s. 348).

Następny poziom, semantyczny, koncentruje się na znaczeniu słów i zdań tworzonych w określonym kontekście, co zapewnia czytelność intencji wypowiedzi. Modele głębokiego uczenia, takie jak sieci rekurencyjne LSTM, są zdolne do uchwycenia znaczeń w dłuższych sekwencjach, co znajduje zastosowanie m.in. w tłumaczeniu maszynowym i analizie opinii (Hirschberg i Manning, 2015, s. 262).

Poziom dyskursywny natomiast analizuje strukturę większych jednostek tekstowych, takich jak akapity czy całe dokumenty, pod kątem ich logicznego układu (Chowdhary, 2020, s. 6). Na tym poziomie analizuje się także spójność i powiązania między jednostkami tekstu, co jest możliwe dzięki narzędziom rozpoznającym elementy dyskursu i ich zależności (Hirschberg i Manning, 2015, s. 262).

Ostatni z opisywanych poziomów, pragmatyczny, bazuje na wiedzy kontekstowej, która nie jest bezpośrednio zawarta w tekście, ale wynika z informacji ogólnych, takich jak wiedza o świecie czy kulturze (Chowdhary, 2020, s. 7). Rozwój systemów NLP w kierunku rozumienia kontekstu i wiedzy ogólnej postępuje, a jedną z trudniejszych

do rozwiązania kwestii jest uwzględnianie dyskursu i intencji użytkownika, co pozostaje wyzwaniem dla przyszłych modeli (Hirschberg i Manning, 2015, s. 263).

2.2 Narzędzia i techniki stosowane w NLP

Klasyczne rozwiązania tworzone w obszarze modeli do analizy języka naturalnego czerpią z nauk statystycznych i wykorzystują między innymi metody analizy probabilistycznej, takie jak n-gramy, czy metody Bayesowskie do analizy tekstów, przy czym już samo przypisywanie części mowy przy użyciu prostych modeli statystycznych potrafiło osiągać dokładność do 90% (Chowdhary, 2020, s. 3). Modele te opierają się na korpusach językowych, czyli dużych zbiorach tekstów pisanych i mówionych, które dostarczają materiału do trenowania i testowania skuteczności algorytmów. Jednym z popularnych rozwiązań było zastosowanie internetowej bazy leksykalnej WordNet, organizującej słowa w synonimiczne zestawy i ułatwiającej ich użycie w zdaniach oraz rozpoznawanie znaczeń wyrazów.

Kolejną techniką, wywodzącą się z teorii automatów i języków formalnych, były między innymi modele automatów skończonych, modele Markowa czy modele językowe n-gramów, szczególnie wykorzystywane w zadaniach korekcji pisowni oraz rozpoznawania i syntezy mowy. Pozwalają one identyfikować kluczowe elementy tekstu, czyli przeprowadzać ekstrakcję informacji, takiej jak nazwy własne czy relacje między jednostkami tekstowymi, co jest niezwykle przydatne w zautomatyzowanym tworzeniu baz danych lub streszczeń (Chowdhary, 2020, s. 3-6).

Kolejnym ważnym etapem jest wstępne przetwarzanie (ang. preprocessing) tekstu w celu przygotowania go do dalszej analizy. Pierwszą z podstawowych metod jest normalizacja, która polega na przekształceniu tekstu do jednolitej formy poprzez usunięcie znaków specjalnych, ujednolicenie wielkości liter czy, w razie potrzeby, usunięcie takich elementów jak tagi HTML. Działania te zmniejszają objętość tekstu i zapobiegają zakłóceniom przy analizie sentymentu czy klasyfikacji (Chai, 2023, s. 518-519). Następnym krokiem bywa usunięcie „stopwords”, czyli słów takich jak „i”, „w” czy „na”, które nie zmieniają znaczenia semantycznego wypowiedzi, a mogą wprowadzać niepotrzebny szum do analizy. Dzięki temu zmniejszana jest wymiarowość danych, a algorytmy mogą bardziej

skoncentrować się na porcjach tekstu istotnie wpływających na sens zdania (Chai, 2023, s. 523-524).

Następną metodą w obróbce jest stemming, czyli proces skracania słów do ich podstawowych form, na przykład „running” do „run”. Działanie to redukuje liczbę unikalnych tokenów, ułatwiając analizę, jednak w niektórych przypadkach może prowadzić do nadmiernego uproszczenia i utraty części znaczenia (Chai, 2023, s. 526-527). Bardziej precyzyjną alternatywą jest lematyzacja, która uwzględnia kontekst gramatyczny w zdaniu i potrafi zamienić słowa do ich form podstawowych, zachowując zarazem właściwy sens – przykładowo „better” zostanie zredukowane do „good”, a nie do „bet” (Chai, 2023, s. 527-528). Istotnym elementem analizy bywa też POS Tagging (Part-of-Speech Tagging), czyli przypisywanie każdemu słowu w zdaniu jego roli gramatycznej. Pomaga to w modelowaniu struktury zdania na potrzeby tłumaczeń maszynowych czy precyzyjniejszej analizy syntaktycznej i może zwiększać dokładność NER przez lepsze zrozumienie kontekstu (Chai, 2023, s. 519).

Ważnym krokiem jest również NER (Named Entity Recognition), który umożliwia identyfikację i klasyfikację nazw własnych, na przykład imion, lokalizacji czy nazw organizacji, co ułatwia porządkowanie danych i pozyskiwanie konkretnej wiedzy z tekstu (Chai, 2023, s. 528-529). Pomimo upływu lat powyższe techniki nadal stanowią podstawę w najnowocześniejszych rozwiązaniach z zakresu NLP i często okazują się kluczowe w budowie efektywnych modeli.

2.3 Zastosowania NLP

W związku z narastającym problemem nadmiaru gromadzonych danych – zarówno w sektorach publicznych, jak i prywatnych, coraz bardziej rośnie udział informacji niestrukturyzowanych, które bez odpowiednich narzędzi do analizy pozostają bezużyteczne. Techniki NLP oferują tu skuteczne rozwiązania, między innymi dzięki integracji z metodami uczenia maszynowego, sztucznej inteligencji i deep learning, co umożliwia dokładniejsze przetwarzanie języka naturalnego oraz przekłada się na łatwiejsze w interpretacji wyniki wspierające proces podejmowania decyzji (Bahja, 2020, s. 1).

Sektory, w których NLP znajduje zastosowanie dzięki analizie danych niestrukturyzowanych, obejmują między innymi obszar biznesu, gdzie odwołanie do konceptu Data-

driven decision making, sformułowanego już w 1953 roku przez Irwina D.J. Brossa, pozostaje kluczowe dla utrzymania konkurencyjności firm na współczesnym rynku (Parra i in., 2023, s. 2365). Wzrost popularności metod analizy danych zrodził duże zainteresowanie wykorzystaniem NLP przy przetwarzaniu danych niestrukturyzowanych, będących często źródłem wiedzy o klientach. Jednym z powszechnych zastosowań jest analiza opinii publicznej o firmie, produktach i trendach konsumenckich, pozyskiwanych z mediów społecznościowych, blogów, komentarzy użytkowników i ankiet online. Początkowo przeprowadza się klasyfikację tekstów w celu ustalenia, czy wypowiedź dotyczy konkretnego produktu, całej oferty czy jakości obsługi, a w dalszej kolejności stosuje analizę wydźwięku, co pomaga ocenić poziom zadowolenia klientów i wskazać potencjalne obszary usprawnień (Mustansir, Shahzad i Malik, 2022, s. 6-10). Zastosowanie tych narzędzi w handlu pozwala lepiej zrozumieć preferencje klientów, co przekłada się na tworzenie skuteczniejszych strategii marketingowych, prognozowanie popytu czy klasyfikowanie wydźwięku opinii jako pozytywny, neutralny lub negatywny (Bahja, 2020, s. 7).

Kolejnym obszarem, w którym NLP odgrywa ważną rolę, jest sektor edukacyjny, gdzie techniki przetwarzania języka naturalnego pomagają w dostosowaniu metod dydaktycznych, ułatwiają prace badawcze i wspomagają proces oceniania (Alhawiti, 2014, s. 72). Skutkuje to wyższą efektywnością kształcenia na różnych poziomach, od szkół podstawowych aż po uczelnie wyższe. Równie istotne jest zastosowanie NLP w sektorze zdrowia, w szczególności przy analizie elektronicznej dokumentacji medycznej i predykcji schorzeń na podstawie historii wizyt pacjentów. Szacuje się, że nawet 80% danych o pacjentach ma charakter niestrukturyzowany, co utrudnia eksplorację i rozpoznawanie wzorców chorobowych. Techniki NLP znajdują zastosowanie przy diagnozowaniu chorób psychicznych, takich jak PTSD czy depresja, i mogą z dużą dokładnością identyfikować objawy stanów psychozy wśród młodzieży (Bahja, 2020, s. 6). Wykorzystuje się je także w predykcji podatności zachorowania na nowotwory, gdzie według niektórych badań uzyskuje się skuteczność na poziomie 87%. Analizie poddaje się historie medyczną pacjenta. Poprzez zestawienie jej z historią pacjentów chorujących na nowotwór modele predykcyjne są w stanie wyodrębnić najistotniejsze czynniki dające rokowania co do potencjalnego rozwoju raka (Osborne i in., 2016, s. 1084).

Istotną rolę techniki NLP pełnią również w analizie treści publikowanych w mediach społecznościowych, co pozwala monitorować popularność oraz trendy wśród użytkowników, a jednocześnie zapewnić im ochronę prywatności. Przykładem odpowiedzialnego wykorzystania tych technologii jest łączenie zagadnień zrównoważonego rozwoju i personalizacji w działaniach marketingowych (Dash, Sharma i Sharma, 2023, s. 5). Narzędzia bazujące na NLP znajdują zatem wszechstronne zastosowanie w wielu dziedzinach życia – zarówno w obszarze publicznym, jak i prywatnym – a ich wdrożenie otwiera nowe możliwości rozwoju przez eksplorację danych niestrukturyzowanych, które inaczej często pozostają niewykorzystane z powodu skali i złożoności.

2.4 Porównanie nowego i klasycznego podejścia

Opisany wcześniej proces tworzenia modeli NLP odnosi się do klasycznego podejścia. Modele te działały w oparciu o założenia nauk statystycznych oraz teorii automatów, nie wykorzystując technik uczenia maszynowego. Głównym założeniem podczas ich tworzenia było ręczne projektowanie cech, takich jak Bag-of-Words, One-Hot Encoding czy TF-IDF. Modele te przekształcały tekst w wysoko wymiarowe wektory, na przykład w modelu BoW dokument reprezentowano za pomocą częstotliwości występowania słów. Metoda TF-IDF dodatkowo uwzględniała unikalność terminów w zbiorze dokumentów. Ze względu na ograniczoną złożoność i brak możliwości uchwycenia pełnego kontekstu, podejście to często prowadziło do niższej skuteczności – duża liczba wymiarów utrudniała również wydajną analizę (Young i in., 2018, s. 56-57).

Kolejnym etapem w rozwoju reprezentacji języka był rozwój tworzenia wektorów właściwościowych tekstu (ang. word embeddings), które przedstawiają słowa jako gęste wektory w nisko wymiarowej przestrzeni, co pozwala uchwycić wzajemne relacje semantyczne. Reprezentacje te były efektywniejsze w rozpoznawaniu związków między wyrazami i w analizie składni zdań, przy jednoczesnym zmniejszeniu wymiarowości wektorów. Następnie wprowadzono Recurrent Neural Networks (RNN) do modelowania danych sekwencyjnych. Sieci LSTM (Long Short-Term Memory) oraz GRU (Gated Recurrent Units) wykorzystują bramy sterujące do regulowania przepływu informacji, co umożliwia przenoszenie istotnych danych na dłuższych odległościach w tekście i poprawia jakość

zadania takiego jak analiza wydźwięku czy tłumaczenie maszynowe (Young i in., 2018, s. 62-64).

Istotnym krokiem było opracowanie modeli opartych na architekturze transformatorów (ang. Transformers), przetwarzających cały kontekst zdania równolegle. Mechanizm self-attention ocenia znaczenie każdego słowa względem pozostałych, co pozwala uchwycić zarówno kontekst lokalny, jak i globalny, bez ograniczeń typowych dla liniowego przetwarzania. Dzięki temu rozwiązaniu, zastosowanemu w modelach BERT i GPT, możliwe stało się sprawniejsze wykorzystanie zasobów i dokładniejsza analiza tekstu (Young i in., 2018, s. 62-64).

W dalszej części tekstu opiszę nowsze narzędzia do analizy języka naturalnego, wykorzystujące najnowsze osiągnięcia w dziedzinie sztucznej inteligencji oraz rozbudowane możliwości przetwarzania dużych zbiorów danych, co pozwala lepiej dostosować modele do różnych zadań NLP.

2.5 Modele wstępnie wytrenowanie

Tworzenie modeli wstępnie wytrenowanych (ang. Pre-trained Models, PTM) stanowi obecnie główny nurt w dziedzinie NLP, ponieważ zrewolucjonizowało sposób uczenia się reprezentacji języka. Modele te wstępnie uczą się uniwersalnych reprezentacji na dużych korpusach tekstowych, zanim zostaną dostosowane do konkretnych zadań językowych. Pozwala im to na uchwycenie ogólnych struktur i zasad językowych, takich jak znaczenie leksykalne czy role semantyczne, co jest kluczowe dla poprawnego rozumienia tekstu (Qiu i in., 2020, s. 1873).

Prace nad modelami wstępnie wytrenowanymi w NLP intensywnie rozwinęły się w 2018 roku, kiedy szerzej zastosowano architekturę opartą na transformatorach. W literaturze wskazuje się przy tym m.in. na znaczenie BERT-a, który jako pierwszy oparł się na ujednoliconym, dwukierunkowym przetwarzaniu tekstu (Mosbach, 2023, s. 1). Według Mosbach i współpracowników (2023), właśnie od tego momentu ukształtował się nowy paradygmat w NLP, w którym dominującą rolę odgrywa reguła „pre-train, then adapt” (Mosbach, 2023, s. 1-2).

Ewolucja historyczna tych rozwiązań znalazła swój przełom w odejściu od statycznych wektorów właściwościowych słów, takich jak Word2Vec czy GloVe, na rzecz kontekstowo-

wych reprezentacji generowanych przez modele typu ELMo, GPT oraz BERT. Pozwoliło to wyraźnie poprawić jakość w wielu zadaniach analizy języka naturalnego, co podkreślają liczne badania opisujące zmiany w wydajności modeli (Mosbach, 2023, s. 1-2).

Istotnym etapem w pełnym wykorzystaniu potencjału modeli wstępnie wytrenowanych jest mechanika dostrajania. Wpływa ona m.in. na stabilność procesu adaptacji i sposoby na poprawę wyników poprzez odpowiednie strategie uczenia (Mosbach, 2023, s. 5-10).

Nowatorskie podejście do wstępnego wytrenowania i dostrajania sprawia, że konieczność trenowania sieci od początku staje się coraz rzadsza, a uniwersalne reprezentacje językowe mogą być skutecznie dostosowywane do wielu nowych zadań. Przewaga modeli wstępnie wytrenowanych staje się najbardziej widoczna w sytuacjach low-data, kiedy liczba dostępnych przykładów jest niewielka (Qiu i in., 2020, s. 1875).

2.6 Tworzenie wektorów właściwościowych

Technika tworzenia wektorów właściwościowych słów polega na przedstawianiu danych językowych za pomocą nisko wymiarowych, ciągłych wektorów, co pozwala uchwycić semantykę języka i relacje między jednostkami leksykalnymi. Osadzenia dzielą się na nie kontekstowe oraz kontekstowe. Te pierwsze, wykorzystywane między innymi w modelach Word2Vec czy GloVe, przypisują każdemu słowu w słowniku jeden stały wektor, niezależnie od kontekstu jego wystąpienia. Ich zaletą jest prostota i zadowalające uchwycenie podstawowej semantyki słów, lecz wadą okazuje się brak elastycznego uwzględniania kontekstu oraz trudności w obsłudze słów spoza korpusu. Aby to obejść, często stosuje się reprezentacje słów na poziomie znaków lub pod słów, jak na przykład FastText czy Byte Pair Encoding (Bakarov, 2018).

Wektory właściwościowe kontekstowe, stosowane w nowszych modelach NLP, dynamicznie uwzględniają kontekst słowa, co rozwiązuje wspomniane wyżej problemy i umożliwia lepsze modelowanie zarówno struktur składniowych, jak i semantycznych. Takie osadzenia generują modele językowe oparte na architekturze sekwencyjnej (RNN z LSTM czy GRU) lub Transformerach z mechanizmem self-attention, pozwalającym na równoległe przetwarzanie całego tekstu oraz na wychwytywanie długodystansowych relacji między słowami (Bakarov, 2018).

Proces tworzenia wektorów właściwościowych tekstu można przedstawić w kilku etapach. Najpierw przeprowadza się tokenizację, polegającą na podziale tekstu na mniejsze jednostki, takie jak słowa, pod słowa (czyli fragmenty wyrazów) lub znaki. Następnie każdemu tokenowi przypisuje się wektor początkowy – może to być losowa inicjalizacja albo wektory właściwościowe wyuczone wcześniej na dużych korpusach. W kolejnym kroku modele językowe tworzą osadzenia z uwzględnieniem kontekstu całego zdania, co pozwala prawidłowo rozpoznawać znaczenie tokenów w różnych sytuacjach językowych. Na koniec można wykorzystać te wektory jako stałą reprezentację wektorową albo poddać je dalszemu dostrajaniu (ang. fine-tuning), dostosowując je do wymagań konkretnego zadania (Bakarov, 2018).

2.7 Wykorzystanie uczenia nienadzorowanego i nadzorowanego

Modele językowe oparte na strategii wstępnego trenowania i późniejszego dostrajania stanowią obecnie standardową praktykę w NLP. W fazie dostrajania model uczy się w trybie nienadzorowanym, zwykle poprzez zadania maskowania tokenów i przewidywania kontekstu, wykorzystując do tego duże, nieetykietowane zasoby tekstowe. Celem jest zbudowanie uniwersalnej reprezentacji językowej, którą w kolejnym etapie dopasowuje się do konkretnego zastosowania poprzez uczenie nadzorowane z użyciem etykietowanych danych. Jak wykazano w porównaniach przeprowadzonych na siedmiu różnych benchmarkach, takie połączenie uczenia nienadzorowanego z nadzorowanym może przynieść nawet 23,4% wyższą skuteczność niż samo uczenie z nadzorem, co jednoznacznie wskazuje na komplementarny charakter obu podejść (Mosbach, 2023, s. 7). Dzięki temu zyskuje się możliwość efektywnego rozwiązywania zadań z zakresu analizy sentymentu, rozpoznawania nazwanych jednostek czy klasyfikacji tekstu, bazując na wiedzy ogólnej przyswojonej w fazie dostrajania, a jednocześnie dostosowując model do ściśle określonego kontekstu użytkowego.

Samo uczenie nienadzorowane w fazie dostrajania przynosi korzyści dzięki ogromnej liczbie dostępnych danych, jednak modele skonstruowane wyłącznie na bazie tego podejścia miewają trudności w zadaniach wymagających ścisłej interpretacji semantycznej i rozpoznawania niuansów składniowych (Mosbach, 2023, s. 9-10). W momencie,

gdy brakuje dobrej jakości etykietowanych przykładów, pojawia się zagrożenie, że sieć może opierać się na korelacjach innych od prawidłowej interpretacji językowej, co staje się szczególnie widoczne w testach out-of-domain, gdzie dane różnią się od tych, na których model był wstępnie uczony (Mosbach, 2023, s. 12). Z kolei przy przechodzeniu do etapu dostrajania, zbyt duże wartości parametrów optymalizacji lub niewłaściwa liczba epok mogą prowadzić do niestabilności trenowania, ale jednocześnie istnieją propozycje skutecznego zredukowania tego zjawiska poprzez uważne dostrajanie współczynników uczenia i uwzględnianie długości zbioru danych treningowych.

W związku z podanymi zaletami i wadami obydwu tych podejść, często przyjmowaną techniką są rozwiązania hybrydowe, w których część cyklu trenowania odbywa się całkowicie w trybie nienadzorowanym, zaś w kolejnej fazie wprowadza się słabe adnotacje (ang. semi-supervision), co pozwala znacząco zredukować liczbę ręcznie etykietowanych danych. Mieszany trening z udziałem uczenia nienadzorowanego i wykorzystującego częściowo etykietowane próbki umożliwia zmniejszenie kosztów treningu nawet o 73%, zachowując przy tym około 98% pierwotnej skuteczności (Mosbach, 2023, s. 14). Takie procedury zwiększają elastyczność modeli i zmniejszają nakłady pracy ludzkiej, a jednocześnie potwierdzają, że połączenie rozległych zasobów nieetykietowanych z częściową formą nadzoru jest kluczem do dalszego rozwoju nowoczesnych systemów przetwarzania języka naturalnego.

2.8 Przegląd aktualnego stanu technologii

Modele analizujące język naturalny opisane powyżej były ważnymi krokami rozwojowymi w dziedzinie NLP, wprowadzając liczne innowacje. Dziedzina ta rozwija się dynamicznie, a naukowcy i firmy nieustannie optymalizują trenowanie oraz proces tworzenia modeli. Rozwój platform takich jak GitHub, Hugging Face czy Kaggle ułatwił udostępnianie badań i kodu, przez co społeczność skupiona wokół NLP szybko się powiększyła. Dzięki tym narzędziom techniki analizy języka naturalnego stały się bardziej dostępne również dla niezależnych programistów, co wpłynęło na decentralizację wiedzy w tym obszarze.

Istotnym wydarzeniem w sztucznej inteligencji było udostępnienie przez OpenAI chatbota ChatGPT, opartego na modelu GPT. Rozwiązanie to zwróciło uwagę na poten-

cjał dużych modeli językowych w różnych zastosowaniach. Szybki wzrost popularności narzędzia pobudził konkurencję ze strony firm takich jak Google, Meta czy Anthropic, jeszcze bardziej zwiększając zainteresowanie tego rodzaju technologiami. Tym samym znaczenie przetwarzania języka naturalnego istotnie wzrosło, a razem z nim zapotrzebowanie na modele NLP.

Jednym z narzędzi oceny i porównywania takich modeli jest Massive Text Embedding Benchmark (MTEB), dostępny na platformie Hugging Face. Zawiera on wiele zadań sprawdzających różne aspekty jakości modeli, m.in. wyszukiwanie semantyczne, klasteryzację, klasyfikację, ponowne sortowanie czy wykrywanie wartości odstających. Test wydajności ocenia zdolność do generalizacji w różnych językach i kulturach, a do mierzenia wydajności wykorzystuje metryki takie jak nDCG, MAP czy F1, odpowiednio dostosowane do konkretnych zadań. MTEB obejmuje 112 zestawów danych z różnych dziedzin, a hierarchiczna struktura benchmarku umożliwia dokładną analizę mocnych i słabych stron modeli (Muennighoff i in., 2023).

Właśnie ze względu na popularność MTEB wykorzystam go do przeglądu wybranych modeli tworzących wektory właściwościowe z czołówki rankingu (stan na 20 stycznia 2025 roku). Ponieważ poszczególne modele często osiągają wysokie wyniki w specyficznych zadaniach, ich praktyczne zastosowanie w innych obszarach bywa zróżnicowane. W kontekście celu niniejszej pracy, czyli oceny wydajności modeli w zadaniu klasteryzacji danych, istotne jest jednak pokazanie, jakie techniki i rozwiązania wpływają na ogólną jakość wyników.

Współczesne modele do tworzenia wektorów właściwościowych w dużej mierze bazują na architekturze transformatorów, które dzięki mechanizmowi samouwagi są w stanie efektywnie przetwarzać długie sekwencje tekstowe oraz uwzględniać związki między odległymi fragmentami wypowiedzi. Przykładem jest NV-Embed-v2, będący aktualnie najwyżej notowanym modelem w rankingu MTEB, z 7,8 miliarda parametrów i maksymalną liczbą 32768 tokenów wejściowych (Hugging Face, 2025). W jego architekturze wykorzystano głębokie sieci neuronowe z wieloma warstwami transformatora oraz integrację danych wizualnych obok tekstowych, co poszerza zakres zastosowań o analizę obrazów i filmów (Lee i in., 2025).

Zbliżone podejście można znaleźć w modelu gte-Qwen2-7B-instruct, bazującym na 7-miliardowej architekturze Qwen2-7B. Tutaj również kluczową rolę odgrywa mecha-

nizm Self-Attention, wspierający przetwarzanie do 32 tysięcy tokenów (Hugging Face, 2025). Wysoki poziom równoległości i możliwość uchwycenia dalekosiężnych powiązań semantycznych przekładają się na dużą precyzję wektorów właściwościowych, co przekłada się na dobre wyniki w zadaniach klasteryzacji tekstu.

Ważną metodą stosowaną w wielu nowoczesnych modelach jest hard-negative mining, czyli selekcja trudnych negatywnych przykładów w trakcie treningu. Pozwala to uczyć się bardziej subtelnych różnic między tekstami, co przekłada się na wyższą jakość wektorów właściwościowych. Rozwiązanie to wykorzystano m.in. w NV-Embed-v2, który w benchmarku MTEB osiągnął pierwszą pozycję w 56 zadaniach (Moreira i in., 2024), oraz w gte-Qwen2-7B-instruct, gdzie stanowi jeden z elementów wieloetapowego uczenia kontrastywnego (Lee i in., 2025).

W przypadku gte-Qwen2-7B-instruct wieloetapowe podejście opiera się także na Domain-adaptive Pretraining, zapobiegającym nadmiernemu dopasowaniu i dostosowującym wektory właściwościowe do różnych kontekstów. Model maksymalizuje podobieństwo między spokrewnionymi tekstami, a minimalizuje je dla przykładów niepowiązanych, co wzmacnia uniwersalność reprezentacji (C. Li i in., 2024).

Wyzwania związane z brakiem nowatorskich i nieprzetworzonych jeszcze zasobów tekstowych sprawiają, że coraz częściej sięga się po generowanie danych syntetycznych. NV-Embed-v2 jest tutaj przykładem wykorzystania tej techniki: w trakcie treningu wygenerowano 120 tysięcy dodatkowych przykładów na bazie 60 tysięcy zdań, korzystając z modelu Mixtral-8x22B-Instruct-v0.1 (Lee i in., 2025). Jak podkreślił Ilya Sutskever podczas konferencji NeurIPS 2024, przyszłość trenowania modeli językowych będzie w dużej mierze oparta właśnie na danych syntetycznych, ponieważ większość łatwo dostępnych treści w Internecie została już wykorzystana przez największe modele LLM (Sutskever, 2024).

Coraz popularniejszym podejściem do efektywnego trenowania modeli z ograniczoną liczbą próbek jest In-Context Learning (ICL). bge-en-icl, stworzony przez Beijing Academy of Artificial Intelligence, bazuje właśnie na tej metodzie. Dzięki niej model może rozwiązywać zadania na podstawie kilku przykładów podanych w komunikatach, bez konieczności pełnego dostrajania parametrów. Zaletą jest zdolność szybkiego dostosowania do nowych zastosowań, co ma znaczenie w sytuacjach, gdy brakuje dużych zbiorów danych (C. Li i in., 2024).

W modelu bge-en-icl (7,1 miliarda parametrów, word embedding do 4096 wymiarów) zastosowano również few-shot learning oraz intensywną optymalizację wektorów właściwościowych, tak by zachować kluczowe informacje semantyczne przy możliwie niedużej liczbie wymiarów. Z uwagi na skupienie się głównie na języku angielskim bge-en-icl osiąga wysoką skuteczność w zadaniach typowo anglojęzycznych i dobrze radzi sobie w kategoriach klasteryzacji w MTEB (Hugging Face, 2025).

Nowoczesne modele językowe mogą również korzystać z Instruct Tuning, polegającego na trenowaniu z wykorzystaniem specjalnie przygotowanych przykładów instrukcji i odpowiedzi. Ponownie ilustruje to gte-Qwen2-7B-instruct, dzięki dodaniu takiego etapu trenowania poprawiono zdolności generacyjne modelu oraz umiejętność odróżniania subtelnych różnic semantycznych. Z kolei bge-en-icl zyskuje dużą elastyczność dzięki multi-task training, który obejmuje równoczesne uczenie modelu na wielu różnych typach zadań (Z. Li i in., 2023).

Wartym wspomnienia rozwiązaniem z obszaru struktur wektorowych są hierarchiczne reprezentacje, inspirowane koncepcją Matryoshka Representation Learning. Model stella_en_1.5B_v5 (1,5 miliarda parametrów, 8192 wymiary wektorów właściwościowych) (Hugging Face, 2025) wykorzystuje wielopoziomową strukturę warstw tekstowych, gdzie wyższe poziomy w hierarchii stanowią uogólnienie informacji z poziomów niższych. Dzięki temu możliwa jest selektywna agregacja informacji, co pomaga w minimalizowaniu redundancji i zwiększaniu przejrzystości reprezentacji (Kusupati i in., 2024).

Stella_en_1.5B_v5, pobrana aż 590 tysięcy razy w okresie grudzień 2024–styczeń 2025, stosuje również restrukturyzację hierarchiczną i dynamikę wielkoskalową – techniki służące redukcji szumu i zachowaniu spójności między różnymi poziomami opisu tekstu. Twórca projektu, Dun Zhang, wprowadził redukcję wymiarowości i kompresję w celu zmniejszenia zapotrzebowania na zasoby. W efekcie model wymaga jedynie 5,75 GB VRAM, co czyni go atrakcyjnym rozwiązaniem w środowiskach lokalnych (Hugging Face, 2025).

2.9 Podsumowanie

Opisane powyżej techniki – od mechanizmu Self-Attention w architekturach Transformer, przez hard-negative mining, generowanie danych syntetycznych, In-Context Lear-

ning, aż po hierarchiczne struktury reprezentacji – przyczyniają się do coraz wyższej skuteczności w zadaniach takich jak klasteryzacja. W rankingu MTEB widać, że choć NV-Embed-v2 osiąga znakomite wyniki w wielu kategoriach, inne modele, takie jak bge-en-icl, gte-Qwen2-7B-instruct czy stella_en_1.5B_v5, również znajdują zastosowanie w praktyce, a w niektórych zadaniach wypadają szczególnie korzystnie.

Wszystkie te przykłady pokazują, że sukces modelu do tworzenia wektorów właściwościowych w dużej mierze zależy od doboru odpowiednich technik treningowych i architektonicznych. W kolejnych rozdziałach szczególną uwagę poświęcę temu, jak powyższe rozwiązania mogą być wykorzystane w praktyce do klasteryzacji danych tekstowych oraz jakie wnioski można wyciągnąć w zastosowaniu biznesowym.

Rozdział 3

Metodyka badawcza

Prognozowanie przychodów z kinowej dystrybucji filmów od lat stanowi interesujący problem badawczy na styku informatyki, ekonometrii oraz zarządzania. W praktyce branża filmowa bazuje głównie na zmiennych liczbowych, czyli budżetach produkcji, kosztach marketingu, terminach premier czy obsadzie aktorskiej (Udandarao i Gupta, 2024). Modele oparte na danych strukturalnych, takie jak regresje liniowe lub drzewa decyzyjne, umożliwiają oszacowanie potencjalnego zwrotu z inwestycji, lecz ich trafność bywa ograniczona. Nieliniowe zależności, które często występują w praktyce, stanowią szczególny problem dla wspomnianych modeli (Zhang, Meng i Xiao, 2024).

Kolejny aspekt to opieranie predykcji jedynie na podstawie metadanych filmowych, już strukturyzowanych, co prowadzi do utraty, czasem kluczowych, porcji danych potrzebnych do postawienia trafnej predykcji (Eliashberg, Hui i John Zhang, 2014). Rozwiązaniem tego problemu jest rozwój narzędzi przetwarzania języka naturalnego i uczenia maszynowego, które pozwalają dziś czerpać informację z treści opisów fabuły, streszczeń czy słów kluczowych. Teksty te mogą ujawniać schematy gatunkowe, motywy narracyjne, a nawet ładunek emocjonalny, które tradycyjnie nie były ujmowane w prognozach. Wzrost skuteczności takich modeli można zaobserwować na przykładzie dodania cech tekstowych ze scenariusza, co skutkuje obniżeniem miary błędu średniokwadratowego o 29 %, w porównaniu do modeli opierających się wyłącznie na metadanych (Eliashberg, Hui i John Zhang, 2014). Celem niniejszej pracy jest empiryczne porównanie skuteczności klasycznych metod ekonometrycznych z modelami wykorzystującymi reprezentacje tekstowe i współczesne algorytmy ML przy predykcji wyników box-office.

Klasyczna część eksperymentu opiera się na popularnych zmiennych liczbowych, natomiast komponent tekstowy wykorzystuje wektory właściwościowe wygenerowane przy pomocy modeli typu uprzednio wytrenowanych transformerów dla krótkich opisów fabuły oraz list słów kluczowych. Wyniki obu podejść zostaną porównane z użyciem tych samych miar oceny.

3.1 Problem badawczy

Kluczowe pytanie niniejszego projektu brzmi, czy rozszerzenie klasycznych modeli ekonometrycznych opartych na zmiennych liczbowych takich jak budżet, termin premiery czy obsada, o reprezentacje tekstu wygenerowane z opisów fabuły i list słów kluczowych rzeczywiście poprawia trafność prognoz przychodów box-office? Odpowiedź ma zarówno wymiar naukowy poprzez weryfikacje wartości dodanej informacji semantycznej, jak i praktyczny, gdyż trafniejsze predykcje wspierają decyzje inwestycyjne w przemyśle filmowym (Chao, Kim i Li, 2023).

Literatura wskazuje, że podejścia bazujące wyłącznie na danych liczbowych często pomijają ukryte sygnały popytu, zakodowane w narracjach gatunkowych, motywach czy ładunku emocjonalnym filmu (Eliashberg, Hui i John Zhang, 2014). Opisy fabuł i słowa kluczowe niosą te informacje, a nowoczesne modele oparte na transformerach potrafią zamienić je w wektorowe reprezentacje, które zachowują złożone zależności semantyczne (Zhang, Meng i Xiao, 2024).

Celem przeprowadzonego eksperymentu jest odpowiedź na pytanie, czy uwzględnienie cech tekstowych pozwoli zmniejszyć typowe miary błędu dla modeli opartych na regresji lub poprawić wskaźniki klasyfikacyjne w porównaniu z dotychczas stosowanymi modelami liczbowymi. Wynik tej konfrontacji pokaże, na ile narracja filmowa może uzupełnić, a być może zastąpić, tradycyjnie wykorzystywane modele predykcyjne przy szacowaniu sukcesu kasowego.

3.2 Hipoteza badawcza

Hipoteza zerowa (H0): Modele predykcyjne, które łączą klasyczne zmienne liczbowe z reprezentacjami wektorowymi tekstu, czyli opis fabuły i słowa kluczowe, osiągają sta-

tystycznie istotnie lepsze wyniki niż modele wykorzystujące wyłącznie dane liczbowe. W praktyce oznacza to niższe wartości miar błędu średniokwadratowego (MSE) czy średniego procentowego błędu prognozy (MAPE) w zadaniu regresji oraz wyższe wskaźniki precyzyjności, czułości i miary F1 w wersji klasyfikacyjnej.

Hipoteza alternatywna (H1) głosi brak takiej przewagi: dodanie cech tekstowych nie poprawia trafności prognoz w sposób istotny na poziomie $\alpha = 0{,}05$.

Podstawą tej tezy są dotychczasowe wyniki badań prac podejmujących się podobnego eksperymentu (Eliashberg oraz Hui i Zhang). Wspomniane przeze mnie wcześniej efekty badaczy sugerują, że narracyjne i gatunkowe sygnały ukryte w tekście mogą być istotnym czynnikiem prognostycznym popytu kinowego, a współczesne techniki NLP potrafią te sygnały przechwycić.

Weryfikacja hipotezy polegać będzie na skonfrontowaniu par modeli, klasyczny kontra rozszerzony o analizę języka naturalnego na wspólnym zbiorze testowym. Jeżeli różnice w metrykach okażą się statystycznie znaczące, H0 nie zostanie odrzucona na rzecz H1, potwierdzając wyższość podejścia łączącego dane liczbowe i tekstowe.

3.3 Cel i zakres badania

Badanie ma charakter porównawczy i ewaluacyjny, mianowicie dąży do empirycznego ustalenia, która z dwóch klas podejść lepiej prognozuje sukces kasowy filmów. Wynik porównania ma dać mierzalny obraz skali przewagi jednego z podejść i wskazać, czy niestrukturyzowane metadane filmowe stanowią realny, praktycznie użyteczny czynnik rokowniczy dla inwestorów i producentów.

Analiza obejmuje filmy produkcji amerykańskiej z lat 2014 – 2024. Takie zawężenie wynika z największej dostępności kompletnych i spójnych rekordów finansowych oraz przejrzystości raportów box-office w tym segmencie rynku. Dla każdego roku pobrano tysiąc najpopularniejszych tytułów z bazy TMDB, co daje korpus liczący łącznie tysiąc filmów dobrej jakości danych (Christmann i in., 2024).

W miejsce bezwzględnych przychodów zastosowano logarytmiczny iloraz (Luo, Macher i Wahlen, 2020):

$$Y = \log\left(\frac{\text{Revenue}}{\text{Budget}}\right)$$

.

Transformacja ta normalizuje przychody z filmów o różnych budżetach, redukuje wpływ wartości odstających i przybliża rozkład do normalnego, co ułatwia estymację wielu metod statystycznych (West, 2022).

Skupienie na rynku amerykańskim pozwala pominąć efekt zróżnicowanych systemów dystrybucji i walut, zaś iloraz przychody/budżet częściowo neutralizuje wpływ inflacji oraz zmian cen biletów na przestrzeni dekady. Zaletą tak określonego zakresu jest możliwość porównywania filmów z różnych roczników na jednej, spójnej skali względnego zwrotu z inwestycji.

3.4 Planowane podejście metodologiczne

Pierwszym etapem badania będzie pogłębiona eksploracja danych, zarówno liczbowych, jak i tekstowych, która pozwoli zidentyfikować rozkłady, potencjalne wartości odstające oraz wstępne korelacje między zmiennymi. Taka analiza wstępna umożliwi nie tylko wykrycie anomalii w zbiorze danych, lecz także ukierunkuje dalsze decyzje dotyczące transformacji zmiennych i wyboru algorytmów predykcyjnych.

W badaniu wykorzystane zostaną dwa rodzaje zmiennych objaśniających. Dane liczbowe obejmą klasyczne zmienne, takie jak budżet produkcji, długość filmu, datę premiery czy liczebność obsady. Dane tekstowe będą składać się z opisów fabuł oraz list słów kluczowych. Materiały te zostaną przetworzone przez uprzednio wytrenowany model do generowania wektorów właściwościowych, oddających semantyczne znaczenie tekstowych metadanych filmowych. Oba typy danych zostaną następnie połączone w jedną macierz cech dla kolejnych etapów modelowania.

W badaniu zostaną utworzone dwa równoległe typy modeli. Pierwsza grupa obejmie regresję liniową oraz algorytmy oparte na grafach trenowane wyłącznie na zmiennych liczbowych, co, jak sugerują wcześniejsze badania, relatywnie dobrze oddaje addytywne zależności, lecz gorzej radzi sobie z ukrytymi, nieliniowymi interakcjami. Druga grupa wykorzysta te same algorytmy, jednak wzbogacone o wektory właściwościowe tekstu, a także modele oparte na metodzie gradient boosting, które mają zwiększyć zdolność do przechwytywania złożonych relacji między zmiennymi tekstowymi i liczbowymi. Oba podejścia zostaną zaimplementowane zarówno w ustawieniu regresyjnym, gdzie zmienną

docelową będzie logarytmiczny stosunek przychodu do budżetu, jak i klasyfikacyjnym, w którym filmy zostaną przypisane do klas sukcesu komercyjnego.

Skuteczność wszystkich modeli będzie mierzona na wspólnym zbiorze testowym przy użyciu identycznego zestawu metryk. Dla regresji zastosowane zostaną MSE oraz MAPE, natomiast dla klasyfikacji – precyzja, czułość i miara F1 wyprowadzane z macierzy pomyłek. Procedura ewaluacji zostanie oparta na walidacji krzyżowej, co zredukuje wariancję wyników i zapewni rzetelność porównania różnych podejść predykcyjnych.

Jednolita metodologia pozyskiwania danych, identyczne kroki wstępnego przetwarzania oraz wspólny sposób walidacji gwarantują, że zaobserwowane różnice w skuteczności modeli będą wynikały wyłącznie z obecności informacji tekstowej, a nie z odmiennych procedur badawczych. Ma to umożliwić obiektywną, statystycznie uzasadnioną ocenę, czy informacje zawarte w opisach filmów i słowach kluczowych faktycznie wnoszą wartość dodaną do prognozowania sukcesu kasowego względem podejść ograniczonych do danych liczbowych.

Rozdział 4

Przygotowanie danych

Przygotowanie danych stanowi kluczowy etap procesu modelowania w uczeniu maszynowym. Procedura ta obejmuje detekcję wartości brakujących, normalizację zmiennych numerycznych oraz przekształcenie zmiennych kategorycznych do postaci akceptowalnej przez modele uczenia maszynowego. Przeprowadzone operacje przygotowawcze umożliwiają weryfikację hipotezy badawczej dotyczącej efektywności modeli hybrydowych w przewidywaniu komercyjnego sukcesu produkcji filmowych.

4.1 Zbieranie danych

W celu zbudowania odpowiednio obszernego zbioru danych do analizy, zaprojektowałem proces pobierania informacji z API The Movie Database (TMDB). Proces ten umożliwił pozyskanie szczegółowych danych o produkcjach filmowych z rynku amerykańskiego z ostatnich czternastu lat.

Zaprojektowany algorytm działa dwuetapowo. W pierwszej fazie pobierane są podstawowe informacje o filmach spełniających założone kryteria. Wykorzystuję endpoint `/discover/movie` wraz z parametrami ograniczającymi wyniki do regionu USA, języka angielskiego oraz sortowania według popularności. Aby zapewnić reprezentatywność próby, dla każdego roku pobieram maksymalnie tysiąc pozycji filmowych, z kontrolowanymi opóźnieniami między zapytaniami.

W drugim etapie każdy zidentyfikowany film podlega rozszerzeniu o szczegółowe atrybuty. Wykonuję trzy uzupełniające zapytania do API, pozyskując dane o parametrach ekonomicznych (budżet, przychody), szczegółach produkcyjnych (data premiery,

Tabela 4.1. Rozkład zebranych filmów, pogrupowany latami

Rok	Liczba filmów
2010	267
2011	283
2012	255
2013	282
2014	260
2015	257
2016	279
2017	252
2018	242
2019	220
2020	118
2021	149
2022	154
2023	195

Źródło: Opracowanie własne

czas trwania), obsadzie oraz słowach kluczowych charakteryzujących treść. Na tym etapie stosuję również filtrowanie jakościowe, eliminując pozycje o niewiarygodnych wartościach finansowych (poniżej 100 jednostek), co pozwala wykluczyć z analizy filmy o niepełnych danych.

Istotnym usprawnieniem procesu jest implementacja wielowątkowości przy pobieraniu szczegółowych informacji. Zastosowanie klasy `ThreadPoolExecutor`[1] umożliwia równoległe przetwarzanie dziesięciu zapytań, co znacząco redukuje czas potrzebny do skompletowania zbioru danych.

Finalnym krokiem procedury jest strukturyzowanie pozyskanych informacji w formie ramki danych przy użyciu biblioteki służącej manipulacji i analizie danych `pandas`[2] i eksport do pliku CSV.

W wyniku opisanej procedury pozyskałem łącznie 3255 rekordów filmowych obejmujących produkcje z lat 2010-2023. Rozkład filmów w poszczególnych latach przedstawiam w tabeli 4.1 na stronie 25.

Warto zwrócić uwagę na znaczący spadek liczby filmów w roku 2020, co bezpośrednio odzwierciedla wpływ pandemii COVID-19 na przemysł filmowy. W kolejnych latach

[1] https://docs.python.org/3/library/concurrent.futures.html
[2] https://pandas.pydata.org/

Tabela 4.2. Opis kolumn w zbiorze danych filmów

Nazwa kolumny	Opis
title	Tytuł filmu w języku angielskim
release_year	Rok wydania filmu (np. 2014)
release_date	Pełna data premiery w formacie RRRR-MM-DD (np. 2018-08-19)
genres	Lista gatunków przypisanych do filmu (np. ['Drama','Horror'])
runtime	Długość trwania filmu wyrażona w minutach (np. 98)
overview	Krótki opis fabuły filmu w języku angielskim
director	Nazwisko reżysera lub reżyserów filmu
writers	Lista scenarzystów odpowiedzialnych za skrypt
main_actors	Główni aktorzy występujący w produkcji (maks. trzech)
budget	Budżet produkcyjny filmu w dolarach amerykańskich
revenue	Globalny przychód filmu w dolarach amerykańskich
keywords	Lista słów kluczowych charakteryzujących treść filmu
production_company	Główna firma produkcyjna odpowiedzialna za film
popularity	Aktualny wskaźnik popularności filmu według TMDB
adult	Wartość logiczna określająca, czy film jest dla dorosłych (true/false)

Źródło: Opracowanie własne

(2021-2022) widoczna jest stopniowa odbudowa rynku, choć liczba produkcji nie powróciła jeszcze do poziomów sprzed pandemii.

Świadomie zdecydowałem się na wykluczenie z analizy filmów z roku 2024, kierując się dwoma istotnymi przesłankami. Po pierwsze, wskaźniki popularności tych produkcji byłyby nieporównywalne z filmami z lat wcześniejszych ze względu na krótszy czas ekspozycji na rynku. Po drugie, ponieważ proces zbierania danych realizowałem na początku 2025 roku, część filmów z 2024 roku wciąż pozostawała w dystrybucji kinowej, co oznaczało niekompletne dane dotyczące ich wyników finansowych. Włączenie takich niepełnych rekordów mogłoby wprowadzić istotne zniekształcenia w późniejszych analizach predykcyjnych.

Pozyskany zbiór danych charakteryzuje się bogatą strukturą informacyjną. Każdy rekord filmowy zawiera 15 różnych atrybutów, które prezentują zarówno aspekty jakościowe, jak i ilościowe produkcji filmowej. Tabela 4.2 na stronie 26 przedstawia szczegółową strukturę pojedynczego rekordu w utworzonym zbiorze danych.

Opisana metodologia pobierania danych stanowi fundament dla dalszych analiz i testowania hipotez badawczych dotyczących zależności występujących w przemyśle filmo-

wym, szczególnie w kontekście weryfikacji skuteczności modeli predykcyjnych łączących dane liczbowe i tekstowe.

4.2 Przetwarzanie i czyszczenie danych

Po zgromadzeniu surowego zbioru danych filmowych, kolejnym niezbędnym etapem było przeprowadzenie procesu czyszczenia i przygotowania danych do analizy. Celem tego etapu było zapewnienie wysokiej jakości materiału badawczego poprzez identyfikację i eliminację potencjalnych problemów, które mogłyby zniekształcić wyniki późniejszych analiz.

W pierwszej kolejności przeprowadziłem szczegółową analizę kompletności danych, identyfikując braki wartości w poszczególnych kolumnach. Brakujące wartości występowały w pięciu kolumnach:

- overview - 2 przypadki,
- writers - 36 przypadków,
- main_actors - 1 przypadek,
- keywords - 112 przypadków,
- production_company - 14 przypadków.

Choć liczba tych braków nie była znacząca w porównaniu z całkowitą liczbą 3255 rekordów, ich obecność mogłaby wpłynąć na wyniki modelowania, szczególnie w przypadku kolumny keywords, która ma kluczowe znaczenie dla weryfikacji postawionej hipotezy badawczej.

Następnym krokiem była identyfikacja wartości odstających (ang. outliers) w zmiennych liczbowych. Do tego celu zastosowałem powszechnie przyjętą metodę opartą na rozstępie ćwiartkowym IQR (ang. Interquartile Range). Procedura obejmowała wyznaczenie pierwszego (Q1) i trzeciego (Q3) kwartyla dla każdej zmiennej liczbowej, obliczenie rozstępu ćwiartkowego `IQR = Q3 - Q1`, a następnie identyfikację wartości wykraczających poza przedział `Q1 - 1.5·IQR, Q3 + 1.5·IQR`. Implementacja tej metody została zrealizowana następująco:

```
q1 = df[col].quantile(0.25)
q3 = df[col].quantile(0.75)
iqr = q3 - q1
lower = q1 - 1.5 * iqr
```

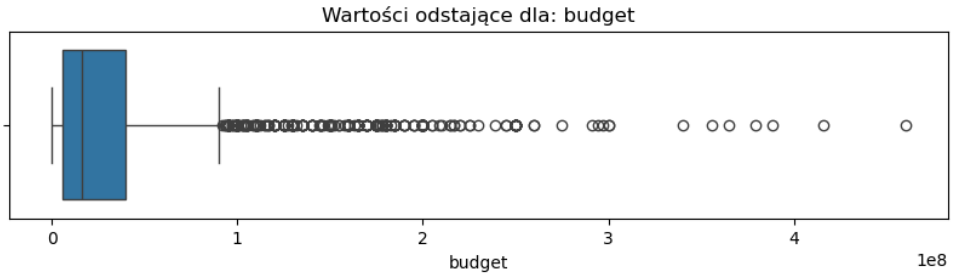

Rysunek 4.1. Wartości odstające dla kolumny budget

Źródło: Opracowanie własne

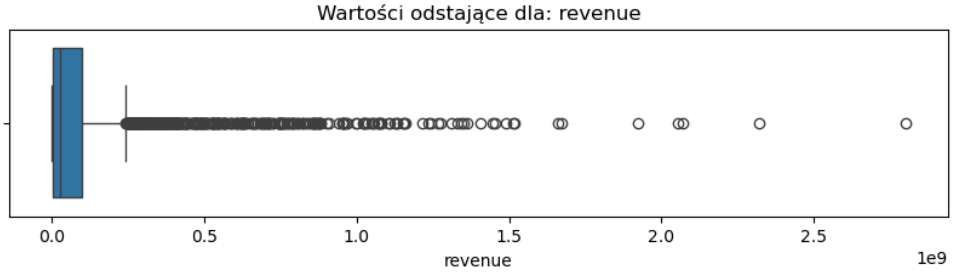

Rysunek 4.2. Wartości odstające dla kolumny revenue

Źródło: Opracowanie własne

```
upper = q3 + 1.5 * iqr
outliers = df[(df[col] < lower) | (df[col] > upper)]
```

Listing 4.1. Kod obliczający IQR

Dla lepszego zrozumienia struktury danych przeprowadziłem szereg wizualizacji przedstawiających rozkład zmiennych liczbowych.

Wartości odstające w budżecie i przychodzie tworzą silny ogon prawostronny, większość filmów finansowana jest kwotami i generuje przychody w przedziałach kilkudziesięciu milionów USD, natomiast pewna grupa projektów przekracza 100–200 mln USD widoczne na wykresie 4.1 oraz 1 mld USD jak zostało przedstawione na wykresie 4.2.

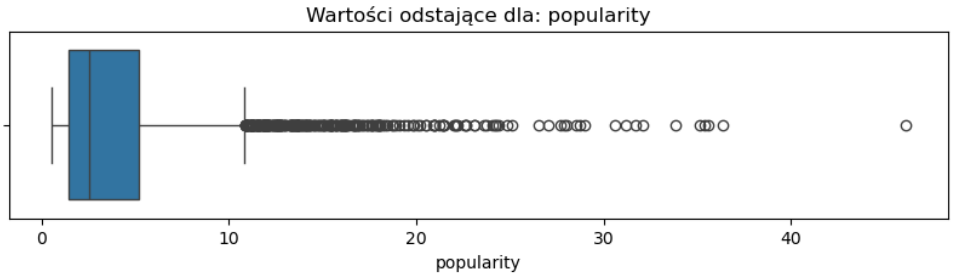

Rysunek 4.3. Wartości odstające dla kolumny popularity

Źródło: Opracowanie własne

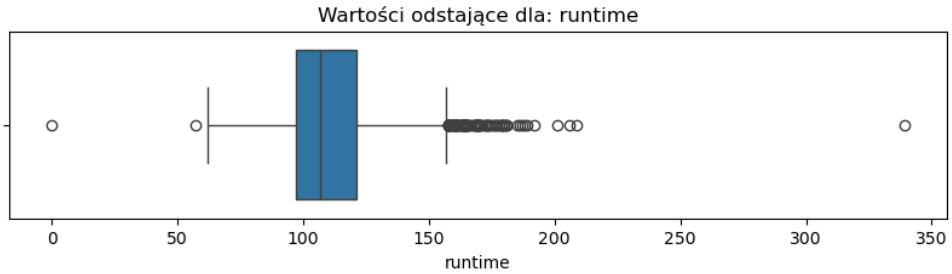

Rysunek 4.4. Wartości odstające dla kolumny runtime

Źródło: Opracowanie własne

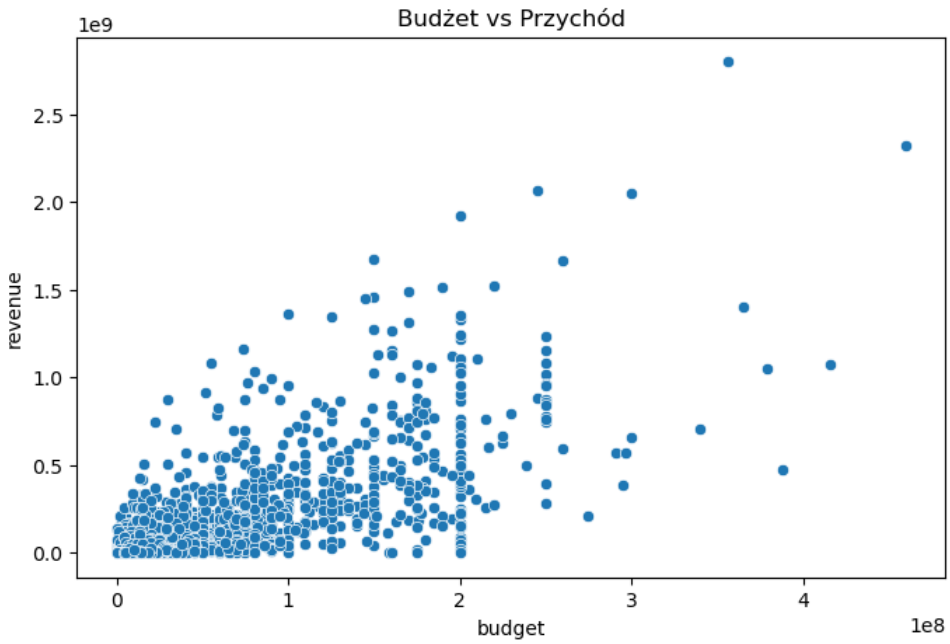

Rysunek 4.5. Budżet a przychód

Źródło: Opracowanie własne

Popularność, jak widać na wykresie 4.3, przyjmuje dominujące niskie wartości (< 10), z nielicznymi punktami powyżej 30, a czas trwania filmu koncentruje się wokół 80–150 minut, z pojedynczymi produkcjami trwającymi poniżej 60 lub powyżej 200 minut, jak widać na wykresie 4.4.

Istnieje wyraźna tendencja rosnąca, zgodnie z wykresem 4.5 na stronie 29, większe budżety przeważnie przekładają się na wyższe przychody. Jednocześnie zauważalna jest zmiana charakteru tego trendu, począwszy od poziomu około 200 milionów USD linia zaczyna się stopniowo zaokrąglać, co wskazuje na efekt malejących przyrostów. Oznacza to, że dalsze zwiększanie budżetu nie przynosi już tak wyraźnych wzrostów przychodów.

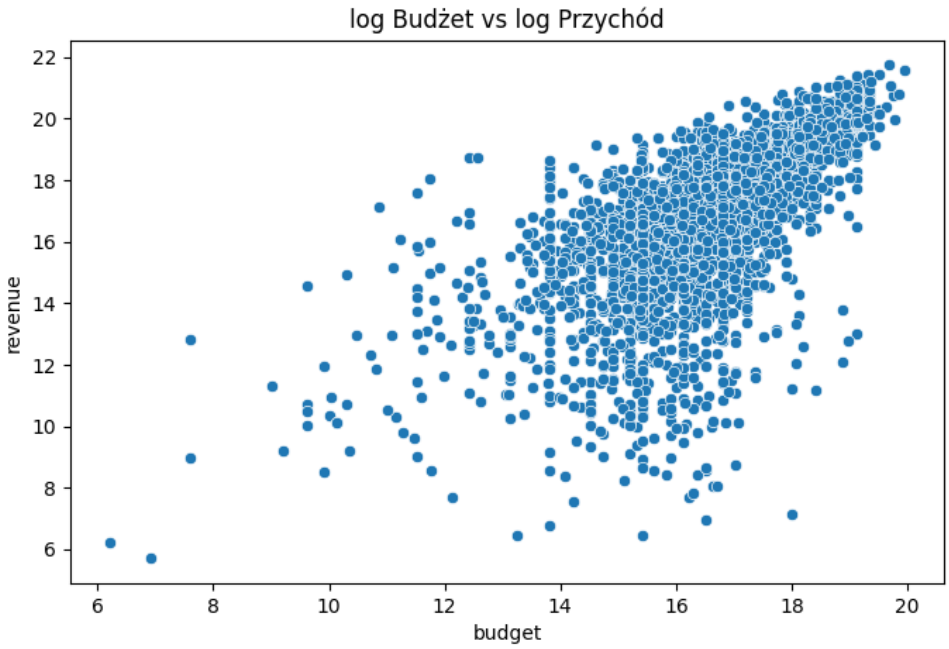

Rysunek 4.6. Logarytm z budżetu a logarytm z przychodu

Źródło: Opracowanie własne

Dla lepszego zobrazowania zależności między budżetem a przychodem, szczególnie w obszarze niższych wartości, przedstawiono także wykres w skali logarytmicznej 4.6. Zastosowanie transformacji logarytmicznej pozwoliło na rozrzedzenie zagęszczonych punktów w dolnym zakresie wykresu, dzięki czemu relacja między zmiennymi stała się bardziej czytelna. W tej skali wyraźniej widać niemal liniową zależność między logarytmem naturalnym budżetu a logarytmem naturalnym przychodu, co wskazuje na to, że przychody rosną szybciej w początkowym zakresie budżetów, a następnie coraz wolniej, zgodnie z typową zależnością nieliniową.

Z kolei, jak widać na wykresie 4.7 ze strony 31, występuje umiarkowana dodatnia korelacja: filmy o wyższej popularności zazwyczaj osiągają większe przychody, jednak przy podobnym poziomie popularności rozpiętość przychodów jest znaczna, czyli od kilkudziesięciu do kilkuset milionów USD, co sugeruje wpływ czynników pozafinansowych na końcowy wynik kasowy.

Wszystkie zmienne finansowe i popularność wykazują silną prawo-skośność, większość obserwacji skupia się przy niższych wartościach, a długi ogon prawostronny reprezentuje nieliczne, ekstremalne przypadki. Zobrazowane zostało to na wykresach 4.8 strona 31, 4.9 strona 32, 4.10 strona 32.

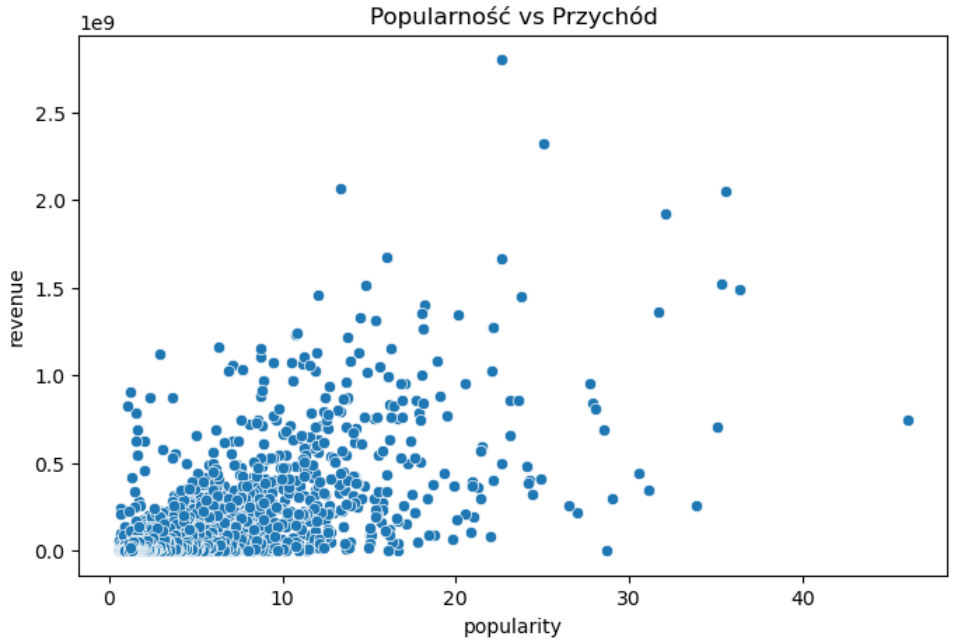

Rysunek 4.7. Popularność a przychód

Źródło: Opracowanie własne

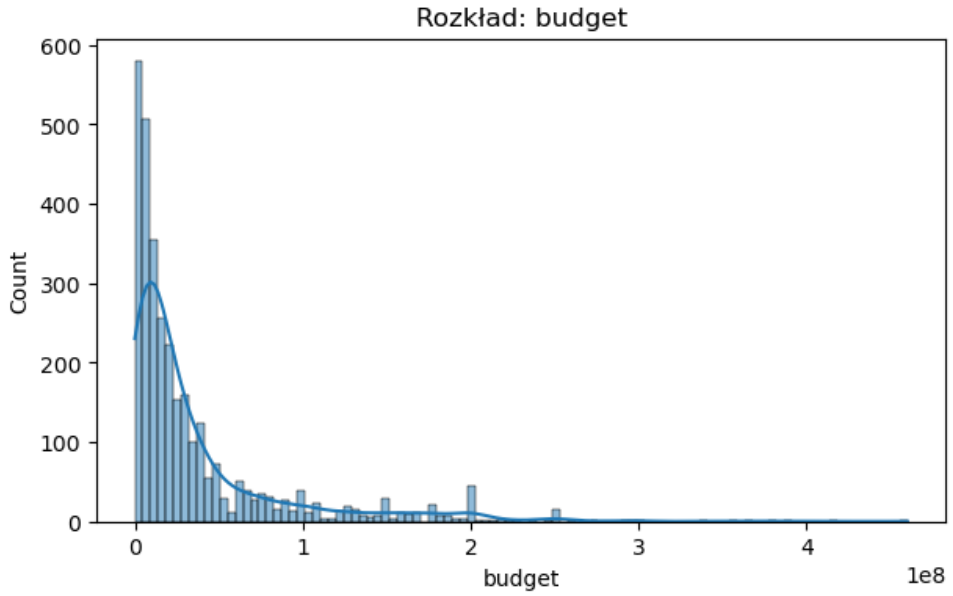

Rysunek 4.8. Rozkład zmiennej budget

Źródło: Opracowanie własne

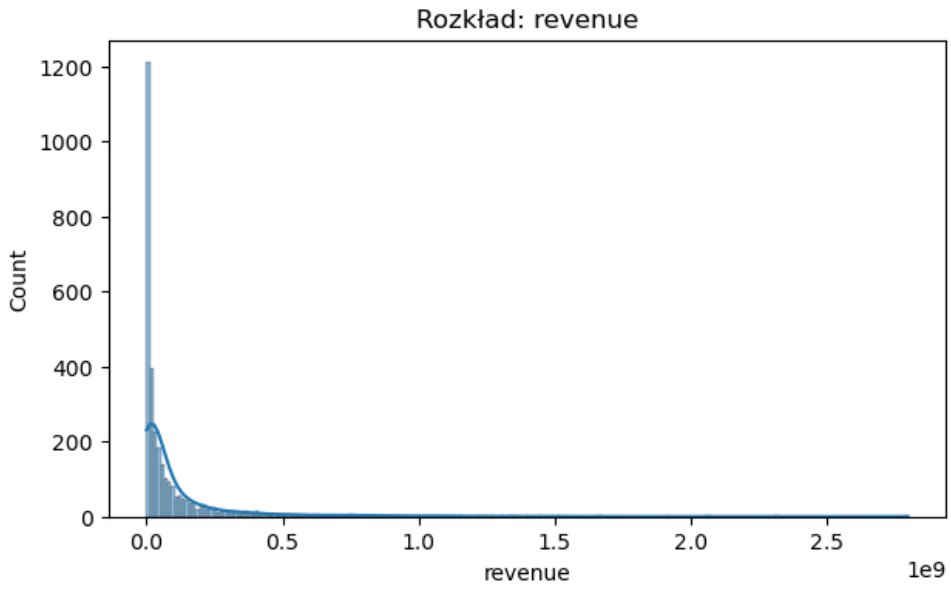

Rysunek 4.9. Rozkład zmiennej revenue

Źródło: Opracowanie własne

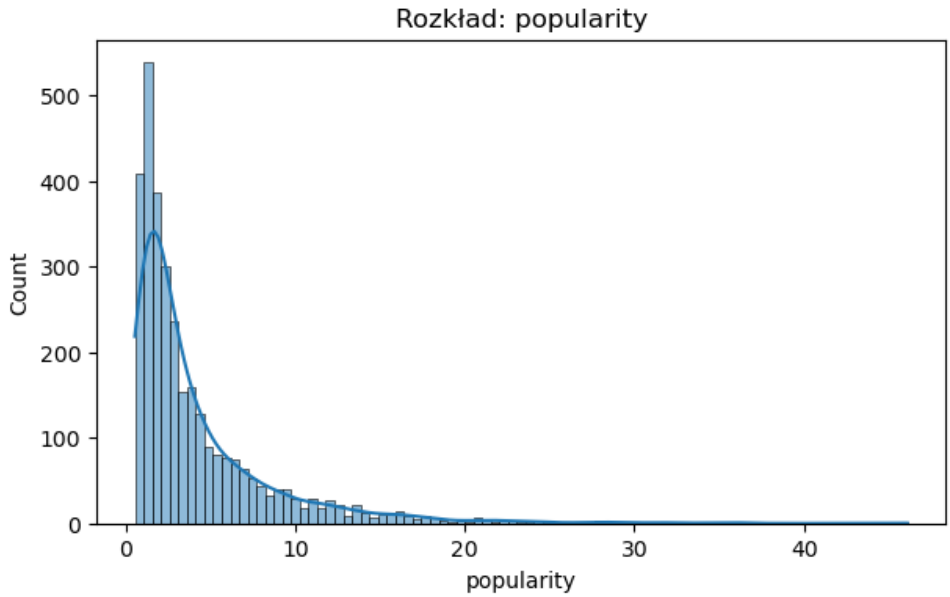

Rysunek 4.10. Rozkład zmiennej popularity

Źródło: Opracowanie własne

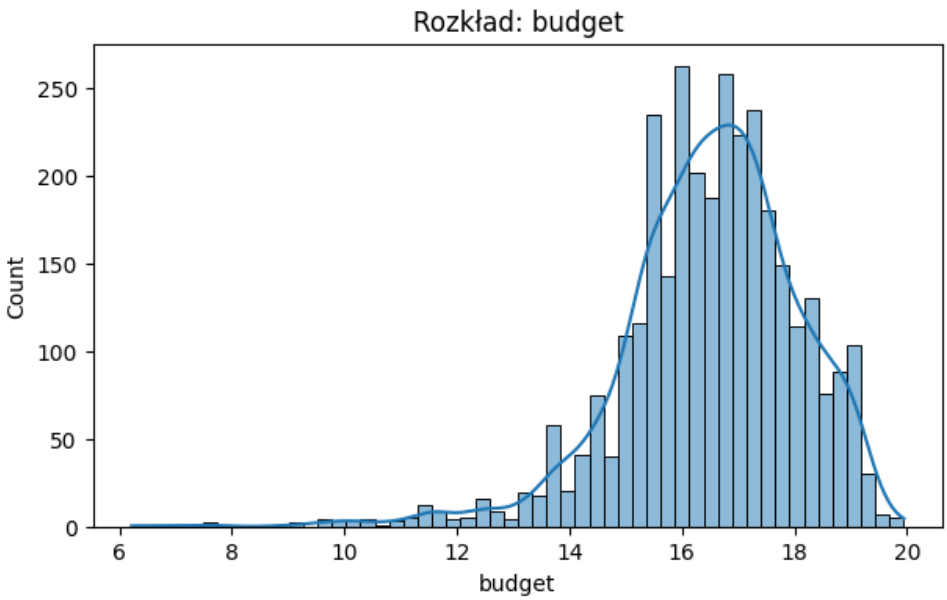

Rysunek 4.11. Rozkład zmiennej log budget

Źródło: Opracowanie własne

W celu złagodzenia efektu silnej prawoskośności oraz poprawy czytelności rozkładów, zmienne poddano transformacji logarytmicznej, za pomocą logarytmu naturalnego. Jak pokazują wykresy rozkładów `log(budget)` (wykres 4.11, strona 33), `log(revenue)` (wykres 4.12, strona 34) oraz `log(popularity)` (wykres 4.13, strona 34), po przekształceniu rozkłady przyjmują kształt bardziej zbliżony do symetrycznego, o wyraźniejszym maksimum i krótszym ogonie, dzięki temu uzyskujemy bardziej zrównoważone rozkłady. W przypadku zmiennych budżetu i przychodu transformacja uwypukla główną masę danych, natomiast dla popularności rozkład nadal pozostaje nieco skośny, choć w znacznie mniejszym stopniu.

Z uwagi na obecność skrajnych wartości odstających oraz utrzymując zasadę zachowania homogeniczności zbioru, wykorzystując bibliotekę `pandas`, w dalszym etapie usunąłem wszystkie rekordy zawierające wartości odstające oraz wiersze z brakującymi danymi. Jednocześnie wyeliminowałem duplikaty i przyporządkowałem poprawne typy danych do każdej kolumny, co jest niezbędne do prawidłowego działania kolejnych algorytmów analitycznych.

Szczególną uwagę poświęciłem przetwarzaniu kolumny keywords, która zawiera słowa kluczowe charakteryzujące treść filmów. Przeprowadziłem analizę statystyczną liczby słów kluczowych przypisanych do poszczególnych filmów, dodając nową kolumnę

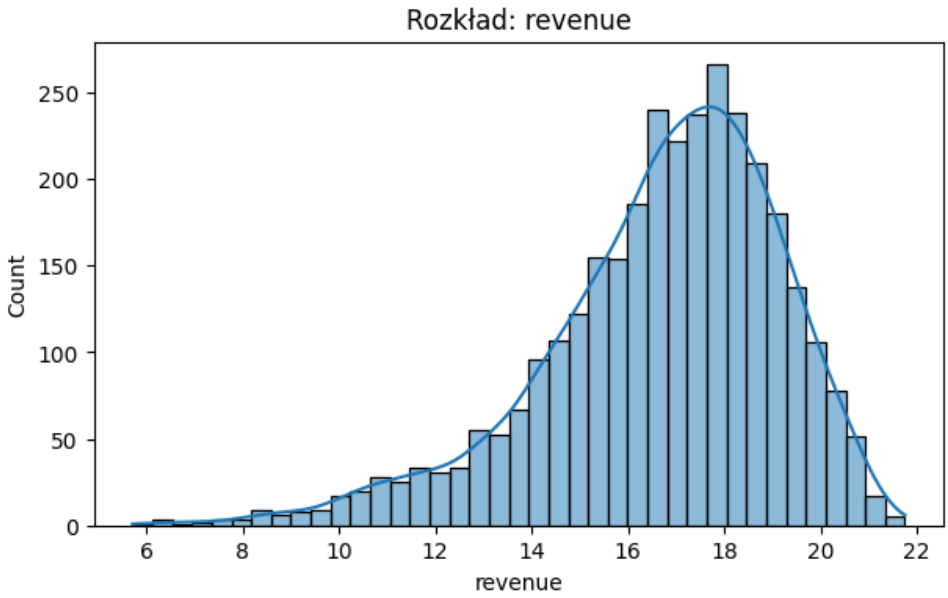

Rysunek 4.12. Rozkład zmiennej log revenue

Źródło: Opracowanie własne

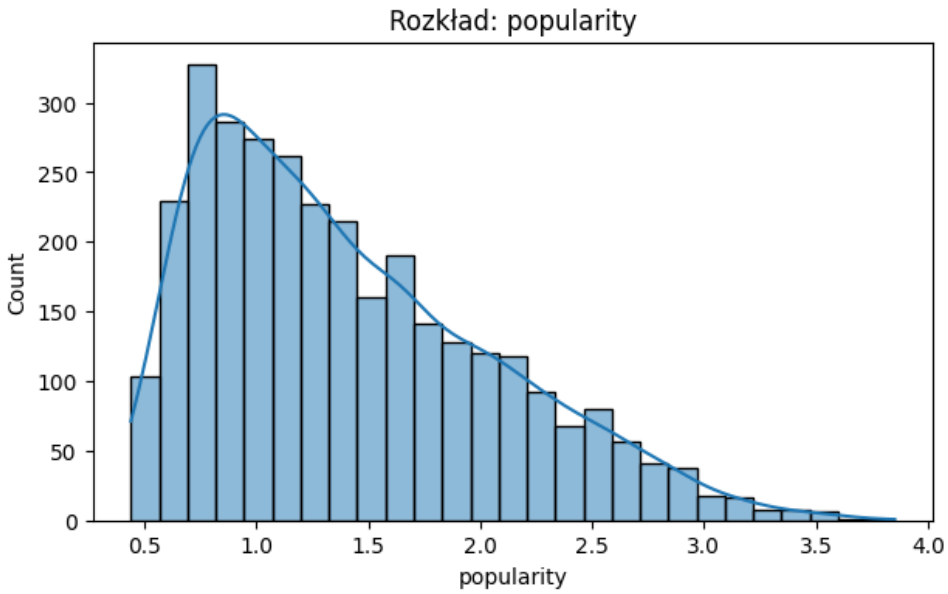

Rysunek 4.13. Rozkład zmiennej log popularity

Źródło: Opracowanie własne

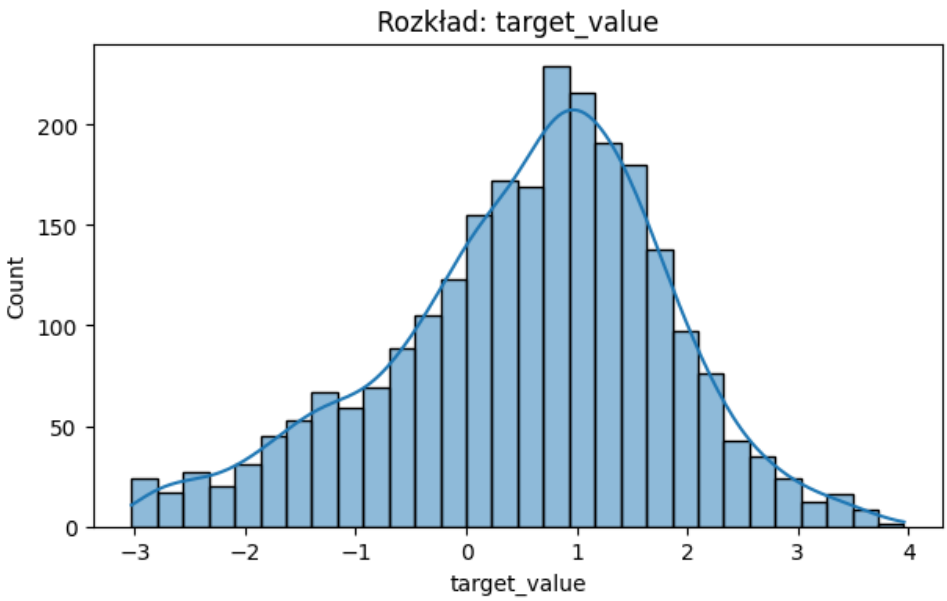

Rysunek 4.14. Rozkład zmiennej docelowej

Źródło: Opracowanie własne

keywords_count, która zlicza liczbę słów kluczowych dla każdego filmu. Podstawowe statystyki dla tej zmiennej prezentują się następująco:

- Średnia liczba słów kluczowych: 10,92
- Mediana liczby słów kluczowych: 9,0
- Odchylenie standardowe: 7,57

Na podstawie tych statystyk ustaliłem próg dla filmów o niskiej liczbie słów kluczowych, stosując formułę: `próg = średnia - odchylenie standardowe`. Obliczony w ten sposób próg wyniósł 3,35. W konsekwencji pozostawiłem w zbiorze danych tylko te filmy, dla których liczba słów kluczowych jest równa lub większa od 4, by zapewnić odpowiednią głębię materiału tekstowego niezbędną do dalszej analizy NLP.

Kolejnym podjętym przeze mnie krokiem było zdefiniowanie i obliczenie zmiennej celu. Tak jak wspomniałem w rozdziale dotyczącym metodyki badawczej, wykorzystam logarytm z ilorazu przychodu oraz budżetu filmowego. Podejście to pozbędzie się problemów wynikających ze skośności rozkładów zmiennych budget i revenue oraz zapewni łatwą interpretacje przy ewaluacji modeli. Na rozkładzie wartości docelowej 4.14 wyraźnie widoczna jest niewielka asymetria w prawo, wartości odstające tworzą długi ogon prawostronny. Większość obserwacji koncentruje się w przedziale od około –1 do 2, ze szczytem gęstości w okolicach 0,5–1,5, co sugeruje, najczęściej występują umiarkowane

wartości. Niemniej jednak pewna grupa przypadków sięga poza ten zakres, osiągając wartości powyżej 3–4, co świadczy o występowaniu znacznego zysku produkcji.

Biorąc pod uwagę rozkład oraz interpretacje zmiennej docelowej zdecydowałem się na następujący podział klasyfikacyjny. Ustalone progi to:

- Flop (Klapa), Y ≤ 0: odpowiada revenue/budget ≤ 1 wielokrotności budżetu. Wynik ten nie generuje zwrotu zainwestowanych środków, a w najlepszym przypadku osiąga jedynie próg rentowności
- Average (Przeciętny), Y zawiera się w 0–1: odpowiada revenue/budget od 1 do ≈2,7 wielokrotności budżetu. Oznacza to umiarkowany zysk zapewniający pokrycie kosztów wydanych na produkcję oraz marketing. Jest to typowy wynik komercyjny dla większości produkcji.
- Hit (Przebój), Y zawiera się w 1–2: odpowiada revenue/budget od ≈2,7 do ≈7,4 wielokrotności budżetu. Kategoria filmów sięgających tego przedziału oznacza znaczny sukces kasowy
- Blockbuster (Hit kinowy) Y > 2: odpowiada revenue/budget > 7,4 wielokrotności budżetu. Filmy sięgające tego pułapu to wyjątkowe fenomeny kinematograficzne, będące globalnymi hitami o nadzwyczajnie wysokich przychodach lub niskobudżetowe produkcje, które przeszły do głównego nurtu.

Wyliczenie łatwo interpretowanej zmiennej wynikowej, a następnie wyznaczenie progów uwzględniających ich znaczenie ekonomiczne wraz z rozkładem zmiennej Y, umożliwia dalszą implementacje w części tworzenia i ewaluacji modeli regresyjnych oraz klasyfikatorów. Natomiast wstępna analiza otrzymanego zbioru danych pozwoliła na pogląd rozkładu i charakteru danych liczbowych oraz dała pojęcie co do dalszej obróbki. Tym samym otrzymany zbiór poddam kolejnym krokom skupiającym się głownie na danych niestrukturyzowanych.

4.3 Analiza i przetwarzanie zmiennych tekstowych

W ramach przygotowania danych do modelowania szczególną uwagę poświęciłem analizie i przetwarzaniu danych niestrukturyzowanych, koncentrując się głównie na słowach kluczowych (keywords) charakteryzujących treść filmów. Ta kategoria danych, rza-

dziej wykorzystywana w tradycyjnych modelach ekonometrycznych, stanowi potencjalnie cenne źródło informacji o cechach jakościowych produkcji filmowych.

Pierwszym krokiem była identyfikacja najczęściej występujących słów kluczowych w zgromadzonym zbiorze danych. Analiza częstotliwości wykazała dziesięć najczęstszych terminów, widocznych w tabeli 4.3 na stronie 38. Występują w niej słowa blisko związane z etapem produkcyjnym filmu, takie jak: oparte na faktach, oparte na książce bądź powieści oraz reżyserka. Inne zwroty związane bezpośrednio z fabułą filmu: Nowy Jork, biografia czy morderstwo. Najwyżej również plasują się informacje o scenach podczas lub po napisach (duringcreditsstinger, aftercreditsstinger).

Na podstawie tej analizy oraz zdecydowałem się na wyodrębnienie kilku kluczowych terminów, które mogą mieć szczególne znaczenie dla komercyjnego potencjału filmów. Do dalszego przetwarzania wybrałem następujące słowa kluczowe:

- based on a novel or book
- sequel
- based on comic
- based on a true story
- marvel
- superhero

Dodatkowo wybrane przeze mnie słowa kluczowe, marvel i superhero, nie plasują się wysoko w zestawieniach najliczniejszych wystąpień, aczkolwiek wybrałem je na podstawie wiedzy własnej. Produkcje związane ze studiem Marvel i tematyką super bohaterską regularnie osiągają sukcesy finansowe pod kątem box-office.

Wybór ten podyktowany był zarówno częstością występowania poszczególnych terminów w zbiorze danych, jak i ich potencjalnym wpływem na sukces komercyjny filmów, co sugerują wcześniejsze badania. Przykładowo, filmy będące adaptacjami powieści, sequele czy produkcje oparte na komiksach, zwłaszcza z uniwersum Marvela, często cieszą się większym zainteresowaniem widowni.

Kolumnę overview w której znajdują się krótkie opisy filmu podane przez producenta zostawiłem nietkniętą. Jako że w poprzednich krokach pozbyłem się z niej wartości pustych, ten zestaw danych jest gotowy do wykorzystania. Model który wykorzystam w celu wygenerowania wektorów właściwościowych jest na tyle zaawansowany, że jakakolwiek

Tabela 4.3. Dziesięć najczęstszych słów kluczowych

Słowo kluczowe	Liczba wystąpień
based on novel or book	382
duringcreditsstinger	280
sequel	260
based on true story	239
woman director	198
aftercreditsstinger	198
murder	184
new york city	155
biography	149
based on comic	149

Źródło: Opracowanie własne

ingerencja z mojej strony w tekście sprowadziłaby się do utraty, potencjalnie kluczowych, informacji semantycznych i kontekstowych.

4.4 Zakodowanie zmiennych kategorycznych

Istotnym etapem przygotowania danych do modelowania była transformacja zmiennych kategorycznych do postaci numerycznej. Proces ten objął zarówno słowa kluczowe, jak i gatunki filmowe oraz informacje o twórcach i producentach, co umożliwiło ich efektywne wykorzystanie w algorytmach.

Pierwszym elementem tego procesu było zakodowanie wybranych słów kluczowych przy użyciu techniki one-hot encoding za pomocą binaryzacji wieloelementowej `MultiLabelBinarizer`[3]. Jak wspomniałem w poprzednim podrozdziale, na podstawie analizy częstotliwości oraz przeglądu literatury wybrałem sześć istotnych terminów i dla każdego z tych słów kluczowych utworzyłem binarną kolumnę w zbiorze danych, gdzie wartość 1 oznacza obecność danego terminu w opisie filmu, a 0 jego brak.

Analogiczne podejście zastosowałem wobec gatunków filmowych. Najpierw przeprowadziłem analizę częstości występowania poszczególnych gatunków w zbiorze danych, a następnie zdecydowałem o usunięciu najrzadziej występujących kategorii, które mogłyby wprowadzać szum do modelu bez wnoszenia istotnej wartości informacyjnej.

[3]https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.MultiLabelBinarizer.html

Pozostałe gatunki zostały zakodowane metodą one-hot, co pozwoliło na ich reprezentację w postaci zestawu zmiennych binarnych.

Znacznie bardziej złożonym wyzwaniem było odpowiednie zakodowanie zmiennych związanych z podmiotami zaangażowanymi w produkcje filmu. W przypadku tych kategorii proste kodowanie one-hot byłoby nieefektywne ze względu na bardzo dużą liczbę unikalnych wartości. Zamiast tego opracowałem metodę rankingową, która pozwoliła na wyodrębnienie najbardziej wpływowych podmiotów i ich odpowiednie zakodowanie. Proces ten przebiegał w trzech etapach.

Pierwszy z nich dotyczył standaryzacji popularności filmów w obrębie roku. Do realizacji tego zadania wykorzystałem funkcję `transform` z biblioteki `pandas`, która automatycznie przelicza surowe wartości na percentyle. Implementacja w pseudokodzie wygląda następująco:

Algorithm 1 Obliczanie percentile popularity dla filmów

```
for każdego release_year filmu do
    zgrupuj filmy według release_year
    for każdej release_year_group do
        oblicz rangę percentylową popularności dla każdego filmu w grupie
        zapisz wynik w nowej kolumnie popularity_percentile
    end for
end for
```

Takie podejście pozwoliło na znormalizowanie wskaźnika popularności w kontekście danego roku, co jest istotne ze względu na upływ czasu, co dałoby nowszym produkcjom nieuczciwą przewagę, oraz zmieniające się trendy i warunki rynkowe.

Następnym krokiem, który podjąłem to sformułowanie funkcji agregującej percentyle dla jednostek. Zdefiniowałem funkcję `calculate_avg_percentile`, która dla dowolnej kolumny zawierającej listę podmiotów, to jest np. reżyserów, zbiera wszystkie obliczone percentyle ich filmów, a następnie oblicza dla każdego podmiotu ich średnią wartość. Funkcja w pseudokodzie wygląda następująco:

Zastosowanie tej funkcji pozwoliło na przypisanie każdemu reżyserowi, scenarzyście, aktorowi czy firmie produkcyjnej unikatowego wskaźnika opartego na średnim percentylu popularności wszystkich filmów, w których brali udział.

Ostatnim krokiem było generowanie i sortowanie rankingu oraz tworzenie zmiennych binarnych. Dla każdej z wybranych kolumn (director, writers, main_actors, production_company) wywołałem powyższą funkcję agregującą, a następnie uporządkowałem

Algorithm 2 Funkcja wyliczająca średni percentyl

```
function CALCULATE_AVG_PERCENTILE(dataframe, nazwa_kolumny)
    utwórz słownik percentile_dict dla przechowywania listy percentyli dla każdego podmiotu
    for każdego wiersza w dataframe do
        if wartość w komórce nie jest listą then
            przekształć ją na listę z jednym elementem
        end if
        for każdego podmiotu w liście do
            pobierz wartość percentyla popularności filmu
            dodaj tę wartość do listy percentyli podmiotu w słowniku
        end for
    end for
    for każdego podmiotu w słowniku do
        oblicz średnią wartość percentyli (suma percentyli / liczba filmów)
    end for
    return słownik z podmiotami i ich średnimi percentylami
end function
```

uzyskane średnie percentyle malejąco i wybrałem 50 najwyższych pozycji. Na podstawie tych rankingów utworzyłem zestaw zmiennych binarnych, stosując następujący algorytm:

Algorithm 3 Tworzenie kolumn zmiennych binarnych

```
for każdej kolumny kategorycznej (director, writers, main_actors, production_company) do
    pobierz listę top 50 podmiotów z rankingu dla tej kategorii
    for każdego podmiotu z listy top 50 do
        utwórz nową nazwę kolumny łącząc nazwę kategorii z nazwą podmiotu
        for każdego wiersza w ramce danych do
            if podmiot znajduje się na liście podmiotów dla tego filmu then
                przypisz wartość 1
            else
                przypisz wartość 0
            end if
        end for
    end for
end for
```

Powyższy kod iteruje przez wszystkie wybrane kolumny kategoryczne, a następnie dla każdego podmiotu z listy najlepszych 50 bytów tworzy nową kolumnę binarną. Wartość 1 jest przypisywana, gdy dany podmiot występuje w liście podmiotów dla danego filmu, a 0 w przeciwnym przypadku.

Ostateczny wynik tego procesu to zestaw zmiennych binarnych, które wskazują na obecność najbardziej wpływowych podmiotów (reżyserów, scenarzystów, aktorów, firm produkcyjnych) w poszczególnych filmach. Dla każdej z czterech kategorii utworzyłem 50 nowych kolumn, co dało łącznie 200 dodatkowych zmiennych predykcyjnych.

Opisana procedura zakodowania zmiennych kategorycznych pozwoliła na efektywne włączenie informacji jakościowych do modeli ilościowych, zachowując jednocześnie rozsądną wymiarowość zbioru danych. Takie podejście umożliwiło uchwycenie wpływu, jaki konkretni twórcy i firmy produkcyjne mogą mieć na sukces komercyjny filmów, co stanowi istotny element weryfikowanej hipotezy badawczej.

Rozdział 5

Tworzenie i weryfikacja modeli

Proces tworzenia i weryfikacji modeli stanowi kontynuację etapu przygotowania danych w przedstawianym eksperymencie. W niniejszym rozdziale zaprezentowano metodologię konstruowania, trenowania oraz oceny skuteczności modeli predykcyjnych ukierunkowanych na prognozowanie sukcesu komercyjnego produkcji filmowych.

Przedstawione procedury badawcze koncentrują się na wykorzystaniu różnorodnych technik modelowania, od podejść klasycznych po zaawansowane metody uczenia maszynowego. Istotnym elementem analizy jest ocena wpływu wektorów właściwościowych na jakość predykcji oraz interpretacja uzyskanych rezultatów w kontekście postawionej hipotezy badawczej. Zastosowane metody ewaluacyjne umożliwiają porównanie efektywności poszczególnych podejść modelowych oraz formułowanie wniosków.

5.1 Generowanie wektorów właściwościowych

Po zakończeniu etapu wstępnego przetwarzania kolumn tekstowych, opisanego w poprzednim rozdziale, kolejnym krokiem jest transformacja tych danych do postaci numerycznej poprzez generowanie wektorów właściwościowych. W ramach niniejszego badania wykorzystano model Qwen3-Embedding-0.6B[1], który funkcjonuje na podobnych zasadach co modele opisane w przeglądzie literatury. Wybór tego modelu wynika z jego wysokich wyników w zadaniach dotyczących klasyfikacji i klasteryzacji tekstu. W rankingu MTEB (stan na dzień 25 czerwca 2025) Qwen3-Embedding-0.6B zajmuje 4 miejsce w tych kategoriach. Kolejnym atutem są niskie wymagania sprzętowe przy ładowa-

[1] https://huggingface.co/Qwen/Qwen3-Embedding-0.6B

niu i korzystaniu z modelu, co umożliwia połączenie jakości wygenerowanych wektorów z jego szeroką dostępnością.

Model Qwen3-Embedding-0.6B wykorzystuje technologię dual-encoder oraz cross-encoder, umożliwiającą efektywne przetwarzanie tekstów o zróżnicowanej długości i strukturze. Architektura modelu, składająca się z 595 milionów parametrów i generująca wektory o 1024 wymiarach, została poddana wielostopniowemu treningowi z wykorzystaniem syntetycznych danych, co znacząco zwiększa jej skuteczność w kontekście analizy treści filmowych.

W procesie generowania wektorów właściwościowych zastosowano zróżnicowane podejście do poszczególnych kolumn tekstowych. W przypadku kolumny overview zrezygnowano z wstępnego przetwarzania tekstu, aby zachować pełną wartość semantyczną i syntaktyczną oryginalnych opisów. Natomiast dla kolumny keywords, ze względu na brak spójności kontekstowej mogącej prowadzić do problemów w dalszych predykcjach, zastosowano metodę uśredniania wektorów właściwościowych dla każdego filmu, co umożliwiło uzyskanie reprezentacji wektorowej przy jednoczesnym zachowaniu istotnych informacji semantycznych.

Do przeprowadzenia obliczeń związanych z generowaniem wektorów właściwościowych wykorzystano środowisko Google Colab, które dzięki dostępowi do akceleracji sprzętowej umożliwiło efektywne przetwarzanie zbiorów tekstowych. Proces obliczeniowy charakteryzował się stosunkowo niskim czasem wykonania, inicjalizacja modelu oraz samo generowanie wektorów zajęło łącznie kilka minut, co stanowi istotną zaletę w kontekście możliwości jego wykorzystania w warunkach ograniczonych zasobów obliczeniowych.

Następnie zweryfikowałem, czy tak wygenerowane reprezentacje wektorowe tworzą grupy filmów o podobnej tematyce. W tym celu zdecydowałem się na wykorzystanie algorytmu `UMAP`[2] (Uniform Manifold Approximation and Projection) do redukcji wymiarowości, co umożliwiło efektywne zastosowanie metody `K-means` do grupowania filmów w klastry o zbliżonej charakterystyce semantycznej.

Wstępnie proces określenia optymalnej liczby klastrów przeprowadzono z wykorzystaniem dwóch metod: metody łokcia oraz wskaźnika silhouette score. Analiza wykresów dla keywords oraz overview za pomocą pierwszej metody nie wykazała jednoznacz-

[2] https://umap-learn.readthedocs.io/en/latest/

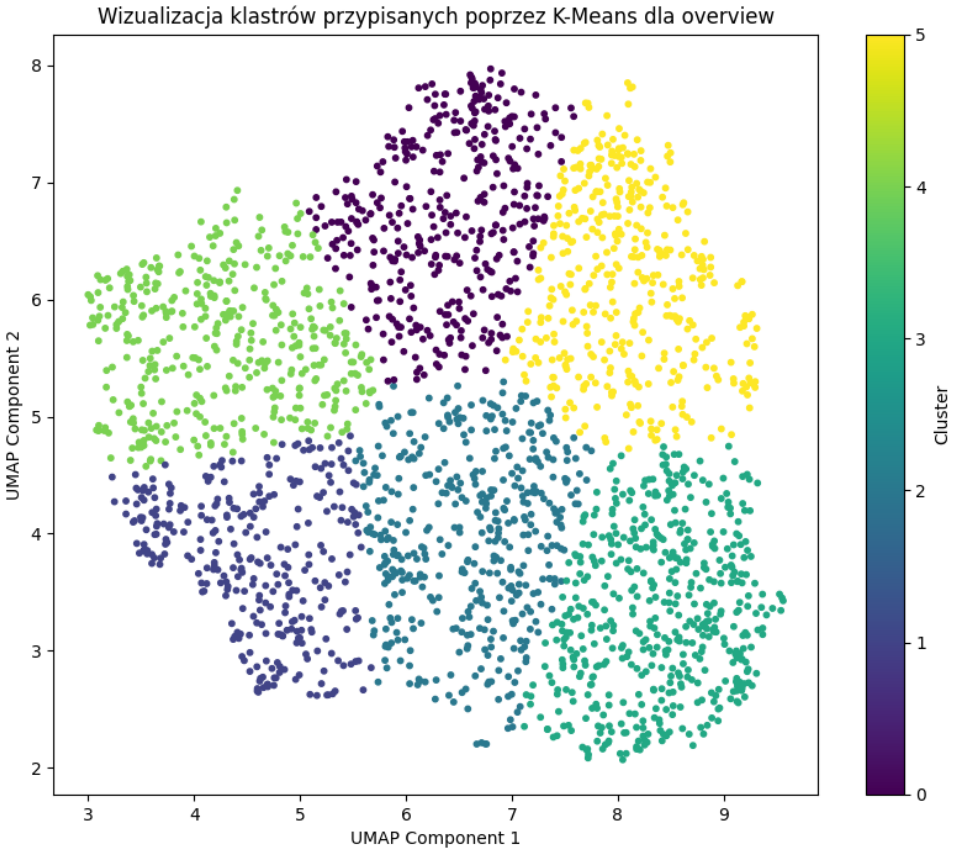

Rysunek 5.1. Wizualizacja klastrów przypisanych poprzez K-means (Overview)

Źródło: Opracowanie własne

nie, jaka liczba klastrów powinna być odpowiednia. W przypadku drugiej metody, optymalna liczba klastrów dla obydwu kolumn to 3.

Pomimo statystycznego uzasadnienia dla wyboru trzech klastrów, po przeprowadzeniu dodatkowych eksperymentów zdecydowałem się na zwiększenie ich liczby do sześciu. Decyzja ta została podjęta ze względu na charakterystykę opisywanych danych. Podział filmów na 3 kategorie jest niewystarczający, aby określić, czy filmy zostały skutecznie pogrupowane tematycznie.

W celu weryfikacji trafności przeprowadzonego grupowania, z każdego klastra wybrano losowo po pięć elementów, zarówno dla wektorów wygenerowanych z kolumny keywords, jak i overview.

Przykładowo, filmy znajdujące się w klastrze 1 overview (wizualizacja na wykresie 5.1), to w większości produkcje kierowane dla dzieci, czyli bajki i animacje, a klaster 2 głównie zawiera horrory i dreszczowce.

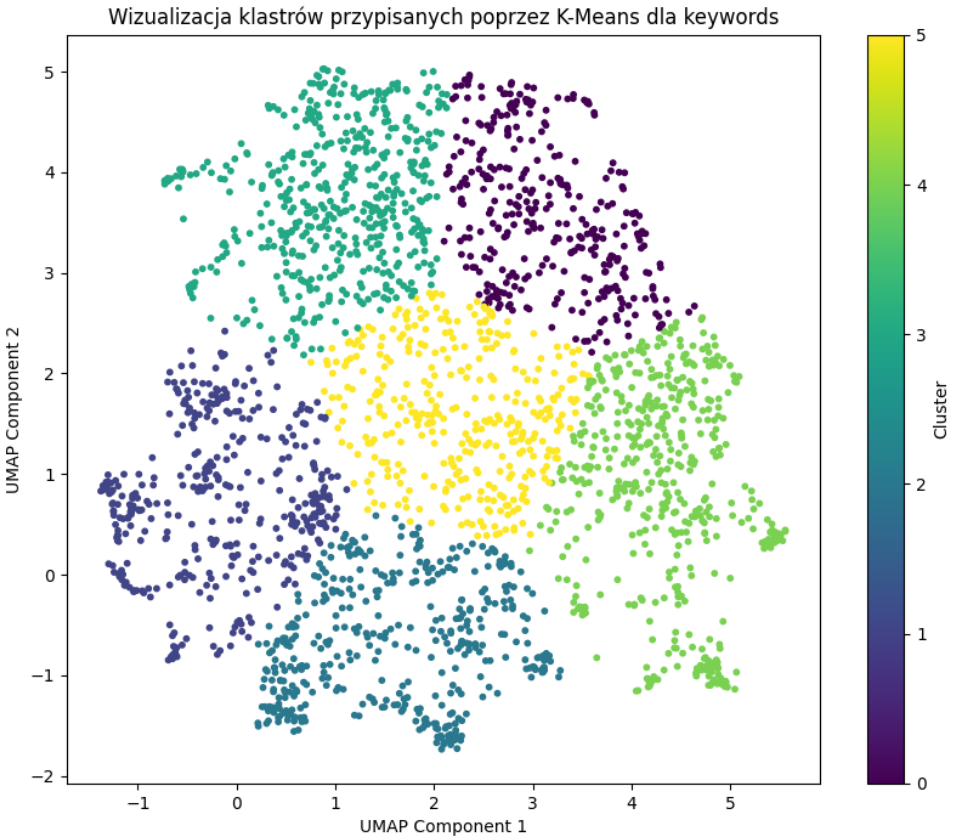

Rysunek 5.2. Wizualizacja klastrów przypisanych poprzez K-means (Keywords)

Źródło: Opracowanie własne

Jasno przedstawione grupy tematyczne znajdziemy również w klastrach utworzonych na podstawie keywords. Klaster 4 zawiera filmy akcji i sensacyjne, a klaster 2 fantastyczne i science-fiction (wykres 5.2)

Wybór ten wykazał wyraźne podobieństwa tematyczne w obrębie poszczególnych klastrów, co zostało przedstawione poprzez powtarzające się gatunki filmowe oraz spójność tematyczną ocenioną na podstawie wiedzy własnej. Obserwacja ta potwierdza skuteczność zastosowanego podejścia w kontekście identyfikacji semantycznych podobieństw między produkcjami filmowymi.

5.2 Modele klasyczne

Modele klasyczne stanowią podstawowy punkt odniesienia dla oceny efektywności bardziej zaawansowanych technik uczenia maszynowego. W ramach przeprowadzonych badań zastosowano je z myślą o porównaniu podejść tradycyjnych z nowoczesnymi metodami, zarówno wykorzystującymi, jak i niewykorzystującymi wektorów właściwościowych. Proces implementacji każdego modelu obejmował staranny dobór parametrów oraz miar oceny jakości predykcji, nastawiony na optymalizację procesu trenowania. W niniejszym oraz następnym podrozdziale dotyczącym treningu modeli uczenia maszynowego korzystałem z biblioteki `scikit-learn`[3], która umożliwiała prostą inicjalizację, strojenie i walidację wykorzystanych modeli. Kolejną kluczową dla tego eksperymentu biblioteką jest `XGBoost`[4], za pomocą której trenowałem modele oparte na metodzie gradient booosting.

Pierwszym zastosowanym modelem klasycznym była regresja liniowa za pomocą modelu `LinearRegression`. W procesie treningu wykorzystano technikę walidacji krzyżowej (Cross Validation) z funkcją celu zorientowaną na maksymalizację współczynnika determinacji R^2.

Analiza efektywności modelu regresji liniowej dostarczyła następujących rezultatów:

- Błąd średniokwadratowy (MSE): 1,5292
- Pierwiastek błędu średniokwadratowego (RMSE): 1,2366
- Średni błąd bezwzględny (MAE): 0,9654

[3] https://scikit-learn.org/stable/index.html
[4] https://xgboost.readthedocs.io/en/stable/

- Współczynnik determinacji R^2: 0,0666

Przedstawione miary dobroci modelu świadczą o istotnych ograniczeniach regresji liniowej w kontekście predykcji logarytmu zwrotu z inwestycji (log(ROI)) dla produkcji filmowych. Szczególnie niski współczynnik determinacji R^2, wynoszący zaledwie 0.07, wskazuje, że model wyjaśnia jedynie nieznaczną część zmienności zmiennej zależnej.

Drugim zastosowanym modelem klasycznym był Random Forest Regressor, który dzięki zdolności do modelowania nieliniowych zależności mógł potencjalnie przezwyciężyć ograniczenia regresji liniowej. W procesie optymalizacji parametrów wykorzystano technikę `RandomizedSearchCV` w połączeniu z walidacją krzyżową `KFold` z pięcioma podziałami zbioru danych. Podobnie jak w przypadku regresji liniowej, funkcja celu była ukierunkowana na maksymalizację współczynnika determinacji R^2.

Ewaluacja modelu Random Forest Regressor dostarczyła następujących wyników:

- Błąd średniokwadratowy (MSE): 1,5277
- Pierwiastek błędu średniokwadratowego (RMSE): 1,2360
- Średni błąd bezwzględny (MAE): 0,9647
- Współczynnik determinacji R^2: 0,0676

Pomimo zastosowania bardziej zaawansowanego algorytmu, zdolnego do modelowania złożonych, nieliniowych zależności, uzyskane wyniki pozostają niesatysfakcjonujące. Współczynnik determinacji R^2 na poziomie 0,0676 wskazuje, że model wyjaśnia jedynie około 6,8% zmienności logarytmu zwrotu z inwestycji. Wysokie wartości błędów RMSE i MAE, zbliżone do tych uzyskanych dla regresji liniowej, potwierdzają ograniczoną zdolność predykcyjną modelu.

Trzecim testowanym modelem klasycznym był Random Forest Classifier, który w przeciwieństwie do poprzednich podejść regresyjnych, został zastosowany do klasyfikacji filmów do odpowiednich kategorii sukcesu komercyjnego. W procesie optymalizacji wykorzystano `RandomizedSearchCV` z funkcją celu ukierunkowaną na maksymalizację dokładności (accuracy), co dało najlepszy wynik spośród innych sprawdzanych miar. Walidację krzyżową `KFold` dostosowano do pięciu podziałów zbioru danych. Ze względu na nierównomierną dystrybucję klas w zbiorze danych zastosowano technikę ważenia klas, której celem była rekompensata niedostatecznej reprezentacji klas mniejszościowych Rozkład klas był następujący:

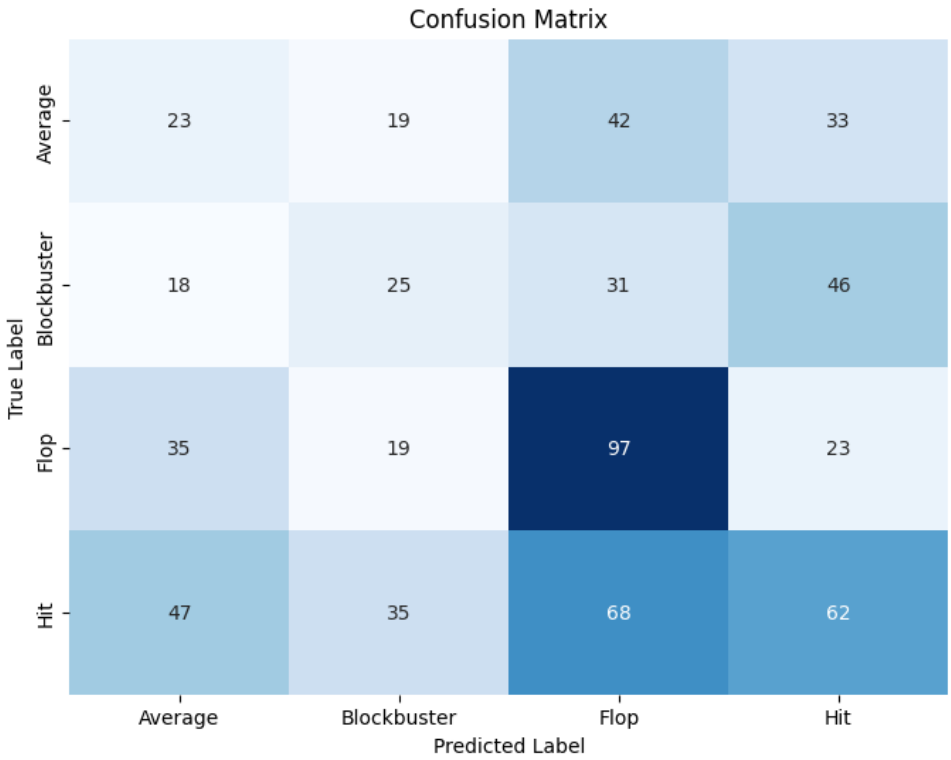

Rysunek 5.3. Macierz pomyłek dla modelu Random Forest Classifier

Źródło: Opracowanie własne

- Hit: 804
- Flop: 730
- Average: 492
- Blockbuster: 465

Ewaluacja modelu Random Forest Classifier przyniosła następujące rezultaty:

- Dokładność (Accuracy): 0,3323
- Precyzja (Precision): 0,3069
- Czułość (Recall): 0,3137
- Wynik F1 (F1 score): 0,3054

Analiza macierzy pomyłek (wykres 5.3) wykazała istotną dysproporcję w skuteczności klasyfikacji poszczególnych kategorii. Najlepsze wyniki osiągnięto dla klasy Flop (F1-score: 0,47, Recall: 0,56, Precision: 0,41), co sugeruje, że model stosunkowo dobrze identyfikuje klasy większościowe. Natomiast najmniej skutecznie rozpoznawana była klasa Average, dla której wszystkie wskaźniki wahały się wokół wartości 0,19-0,20.

Choć ogólna dokładność modelu na poziomie 33,23% przewyższa skuteczność losowego przypisywania klas (25% przy czterech równolicznych klasach), różnica ta nie jest na tyle znacząca, aby uznać model za efektywny w kontekście praktycznych zastosowań. Niska wartość wskaźników Precision, Recall oraz F1-score dla poszczególnych klas, szczególnie tych mniejszościowych, wskazuje na ograniczoną zdolność modelu do poprawnej identyfikacji kategorii sukcesu komercyjnego.

Następnym testowanym modelem był już bardziej zaawansowany XGBoost Regressor. W procesie optymalizacji hiperparametrów zastosowano metodę `BayesSearchCV`[5] (z parametrem n_iter = 30) zamiast tradycyjnej `RandomizedSearchCV`, co umożliwiło bardziej efektywne przeszukiwanie przestrzeni parametrów dzięki wykorzystaniu podejścia bayesowskiego. Jako funkcję celu wybrano minimalizację pierwiastka średniokwadratowego błędu (neg_root_mean_squared_error), a walidację przeprowadzono z wykorzystaniem pięciokrotnego podziału zbioru danych `KFold`. Reszta parametrów treningu została dopasowana na podstawie ręcznej kalibracji, dopasowując jak najlepsze wartości.

Ewaluacja modelu XGBoost Regressor dostarczyła następujących wyników:

- Błąd średniokwadratowy (MSE): 1,3918
- Pierwiastek błędu średniokwadratowego (RMSE): 1,1798
- Średni błąd bezwzględny (MAE): 0,9207
- Współczynnik determinacji R^2: 0,1331

Pomimo zastosowania bardziej zaawansowanego algorytmu, wyniki wciąż pozostają niesatysfakcjonujące. Wartość MAE na poziomie 0,9207 wskazuje, że średnie odchylenie przewidywań od rzeczywistych wartości logarytmu zwrotu z inwestycji wynosi niemal jednostkę, co stanowi znaczący błąd w kontekście praktycznych zastosowań. Współczynnik determinacji R^2 równy 0,1331 sugeruje, że model wyjaśnia jedynie około 13,3% zmienności zmiennej zależnej, co jest wprawdzie lepszym wynikiem niż w przypadku Random Forest Regressor, ale nadal niewystarczającym dla efektywnej predykcji. Wysokie wartości MSE i RMSE potwierdzają znaczną rozbieżność między przewidywaniami modelu a rzeczywistymi wartościami, wskazując na ograniczoną zdolność predykcyjną nawet przy wykorzystaniu zaawansowanych technik gradient boosting.

[5] https://scikit-optimize.github.io/stable/modules/generated/skopt.BayesSearchCV.html

Ostatnim z klasycznych modeli poddanych analizie był XGBoost Classifier, ukierunkowany na klasyfikację filmów do odpowiednich kategorii sukcesu komercyjnego. Ze względu na nierównomierny rozkład klas w zbiorze danych, tak jak w przypadku modelu Random Forest Classifier, zastosowano technikę ważenia klas, mającą na celu poprawę skuteczności klasyfikacji klas mniejszościowych Average i Blockbuster.

W procesie optymalizacji hiperparametrów wykorzystano metodę `BayesSearchCV` z funkcją celu ukierunkowaną na maksymalizację średniej wartości F1 dla całości (f1_macro), co miało zapewnić zrównoważoną skuteczność klasyfikacji wszystkich kategorii niezależnie od ich liczebności. Do walidacji zastosowano `StratifiedKFold` z pięcioma podziałami zbioru danych, co pozwoliło zachować proporcje klas w poszczególnych zestawach treningowych i testowych.

Ewaluacja modelu XGBoost Classifier dostarczyła następujących wyników:

- Dokładność (Accuracy): 0,4103
- Precyzja (Precision): 0,3958
- Czułość (Recall): 0,3928
- Wynik F1 (F1 score): 0,3888

Analiza macierzy pomyłek (wykres 5.4 wykazała znaczące zróżnicowanie w skuteczności klasyfikacji poszczególnych kategorii. Najlepsze wyniki osiągnięto dla klasy Flop (Precision: 0,43, Recall: 0,58, F1-score: 0,49), co wskazuje na stosunkowo dobrą zdolność modelu do identyfikacji produkcji filmowych odnoszących porażkę komercyjną. Natomiast najmniej skutecznie rozpoznawana była klasa Average (Precision: 0,31, Recall: 0,27, F1-score: 0,29), pomimo zastosowania techniki ważenia klas.

Model osiągnął ogólną dokładność na poziomie 41,03%, co stanowi poprawę w stosunku do modelu Random Forest, jednak wartość ta pozostaje umiarkowana w kontekście praktycznych zastosowań. Zbliżone wartości wskaźników Precision, Recall oraz F1-score dla całego modelu (oscylujące wokół 0,39) wskazują na stosunkowo zrównoważoną zdolność predykcyjną, choć z wyraźną preferencją dla klas większościowych pomimo zastosowanych technik równoważenia. Wyniki te sugerują, że choć model przewyższa efektywność Random Forest Classifier, nadal istnieje znaczący potencjał do poprawy poprzez włączenie dodatkowych źródeł informacji, takich jak wektory właściwościowe.

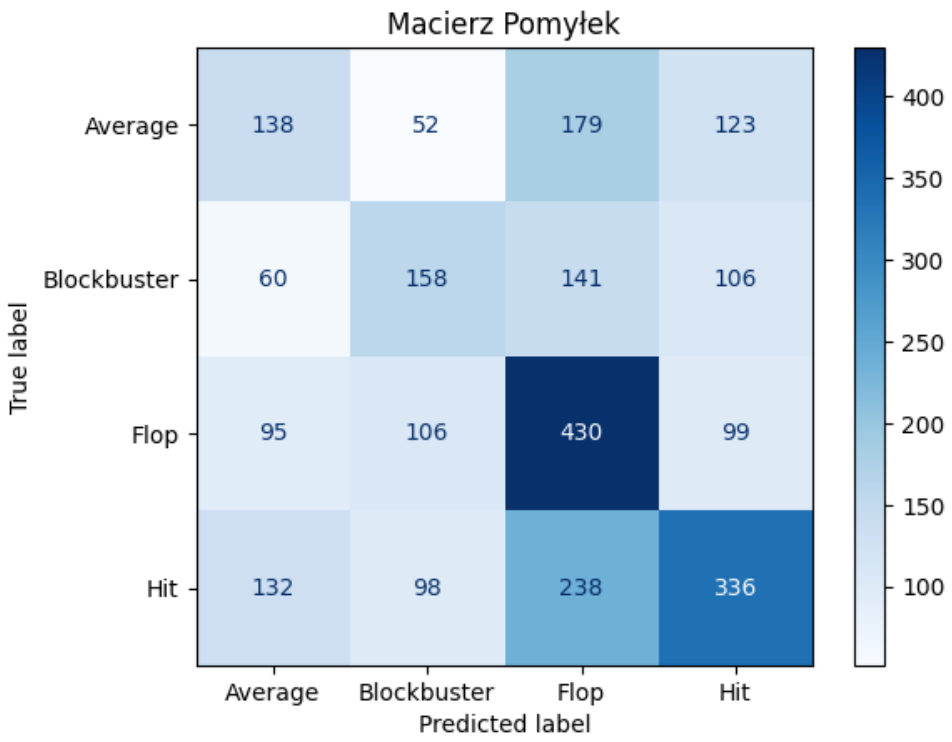

Rysunek 5.4. Macierz pomyłek dla modelu XGBoost Classifier bez wektorów właściwościowych

Źródło: Opracowanie własne

5.3 Modele wzbogacone o wektory właściwościowe

Głównym celem tej części analizy jest porównanie skuteczności modeli wykorzystujących wyłącznie standardowe cechy ilościowe z modelami wzbogaconymi o wektory właściwościowe wygenerowane z danych tekstowych, ze szczególnym uwzględnieniem technologii `XGBoost`. W każdym z procesów treningu modeli, strojenie parametrów wejściowych odbywało się ręcznie, na podstawie porównania miar dobroci modeli i wiedzy eksperckiej.

Pierwszym z modeli wzbogaconych o wektory właściwościowe poddanym analizie był XGBoost Regressor. Z uwagi na wysoką wymiarowość danych po uzupełnieniu modelu, zastosowano technikę redukcji wymiarowości `PCA`, ograniczając liczbę wymiarów do 200 komponentów, co pozwoliło zachować około 85% wariancji oryginalnych danych. Jak wykazały eksperymenty, podejście to przyniosło lepsze rezultaty niż wykorzystanie surowych wektorów właściwościowych.

Ze względu na zwiększoną złożoność obliczeniową modelu, zmodyfikowano parametry procesu walidacji oraz optymalizacji hiperparametrów. Zastosowano trzyczęściowy

podział zbioru danych oraz ograniczono liczbę iteracji w metodzie `BayesSearchCV` do 10, zachowując jednocześnie tę samą funkcję celu (neg_root_mean_squared_error).

Do interpretacji wyników modelu wykorzystano bibliotekę `SHAP`[6] (SHapley Additive exPlanations), która umożliwiła identyfikację 15 najistotniejszych cech wpływających na predykcję. Analiza wykazała, że zdecydowaną większość najważniejszych cech stanowiły komponenty pochodzące z wektorów właściwościowych, co potwierdza istotną rolę informacji semantycznych w procesie predykcji sukcesu komercyjnego.

Ewaluacja modelu XGBoost Regressor z wektorami właściwościowymi przyniosła następujące rezultaty:

- Błąd średniokwadratowy (MSE): 1,0364
- Pierwiastek błędu średniokwadratowego (RMSE): 1,0180
- Średni błąd bezwzględny (MAE): 0,7994
- Współczynnik determinacji R^2: 0,3545

Uzyskane wyniki wskazują na znaczącą poprawę jakości predykcji w porównaniu z modelem niewykorzystującym wektorów właściwościowych. Wartość MAE zmniejszyła się o ponad 0,12 jednostki, osiągając poziom poniżej 0,8, co świadczy o istotnie mniejszych błędach predykcji. Szczególnie zauważalna jest poprawa współczynnika determinacji R^2, który wzrósł do 0,3545, wskazując, że model wyjaśnia ponad 35% zmienności logarytmu zwrotu z inwestycji, niemal trzykrotnie więcej niż w przypadku modelu bez wektorów właściwościowych. Niższe wartości MSE i RMSE również potwierdzają lepszą jakość dopasowania modelu do danych. Wyniki te jednoznacznie wskazują na znaczący potencjał wektorów właściwościowych w zwiększaniu efektywności szacowania zmiennej zależnej log(ROI).

Ostatnim modelem poddanym analizie był XGBoost Classifier z wykorzystaniem wektorów właściwościowych. Podobnie jak w przypadku poprzedniego, zastosowano technikę redukcji wymiarowości `PCA`, ograniczając liczbę wymiarów wygenerowanych wektorów z 1024 do 200 komponentów, utrzymując tym samym 85% wariancji. Dodatkowo, wykorzystano wcześniej obliczone wagi klas w celu zrównoważenia wpływu nierównomiernej dystrybucji kategorii na proces uczenia.

Zarówno jak u poprzednika, zmodyfikowano parametry procesu walidacji, stosując `StratifiedKFold` z trzema podziałami zbioru danych. Optymalizację hiperparametrów

[6] https://shap.readthedocs.io/en/latest/

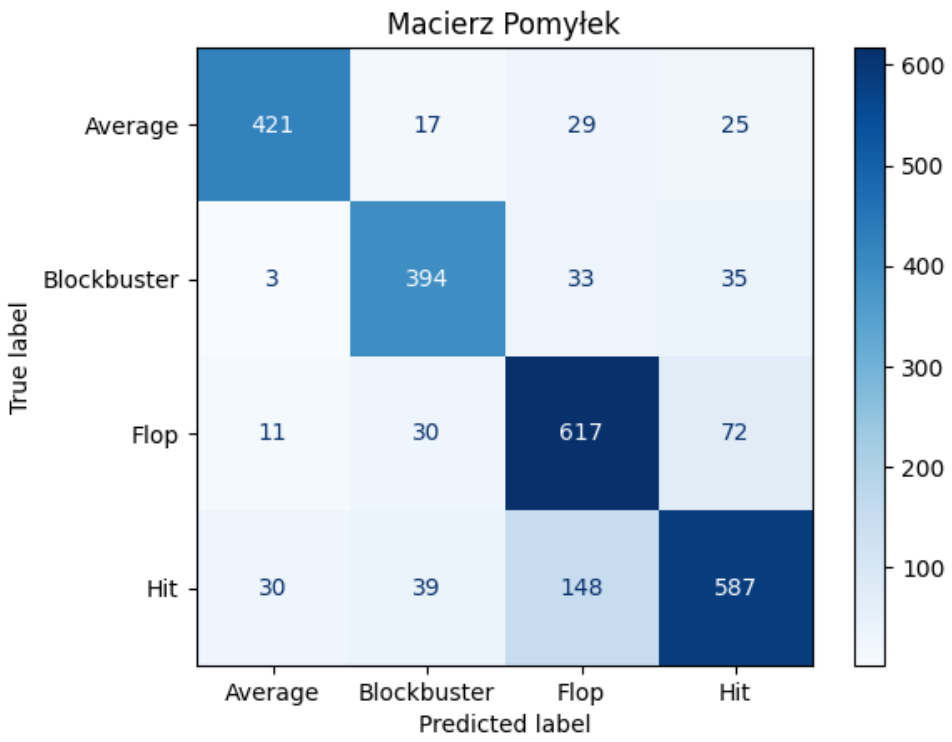

Rysunek 5.5. Macierz pomyłek dla modelu XGBoost Classifier z wykorzystaniem wektorów właściwościowych

Źródło: Opracowanie własne

przeprowadzono z wykorzystaniem metody `BayesSearchCV`, ukierunkowanej na maksymalizację średniej makro wartości F1.

Ewaluacja modelu XGBoost Classifier z wektorami właściwościowymi przyniosła wyjątkowo obiecujące rezultaty:

- Dokładność (Accuracy): 0,8105
- Precyzja (Precision): 0,8222
- Czułość (Recall): 0,8196
- Wynik F1 (F1 score): 0,8193

Z macierzy pomyłek (rysunek 5.5) można jednoznacznie wywnioskować znaczącą poprawę w klasyfikacji wszystkich kategorii, ze szczególnym uwzględnieniem klas mniejszościowych, które w poprzednich modelach były identyfikowane ze stosunkowo niską skutecznością. Tym razem najlepsze wyniki osiągnięto dla klasy Average (Precision: 0,91, Recall: 0,86, F1-score: 0,88), co stanowi radykalną poprawę w porównaniu z klasycznymi modelami. Nawet kategoria Hit, dla której osiągnięto najniższe wartości wskaźni-

ków (Precision: 0,82, Recall: 0,73, F1-score: 0,77), charakteryzuje się znacznie wyższą skutecznością klasyfikacji.

Ogólna dokładność modelu na poziomie 81,05% oznacza niemal dwukrotną poprawę w stosunku do najlepszego klasycznego modelu klasyfikacyjnego i ponad trzykrotną przewagę nad losowym przypisywaniem klas. Zbliżone wartości wskaźników Precision, Recall oraz F1-score (wszystkie powyżej 0,81) wskazują na zrównoważoną i wysoką skuteczność modelu w klasyfikacji wszystkich kategorii sukcesu komercyjnego.

Analiza SHAP wykazała, że podobnie jak w przypadku modelu regresyjnego, zdecydowaną większość najistotniejszych cech stanowiły komponenty pochodzące z wektorów właściwościowych. Interesujących wniosków dostarczyła również analiza wpływu poszczególnych gatunków filmowych na predykcję. Okazało się, że drugim najważniejszym czynnikiem dla identyfikacji filmów z kategorii Blockbuster jest przynależność do gatunku Horror, co sugeruje, że produkcje z tego gatunku mają zwiększoną szansę na osiągnięcie nadzwyczajnego sukcesu komercyjnego. Z drugiej strony, trzecim najistotniejszym predyktorem dla kategorii Flop okazała się przynależność do gatunku Comedy, wskazując na podwyższone ryzyko porażki finansowej w przypadku komedii.

W ramach sprawdzenia alternatywnych podejść do modelowania, przeprowadzono również eksperymenty z wykorzystaniem modelu LightGBM, stanowiącego konkurencyjną implementację algorytmu gradient boosting względem XGBoost. Głównym celem tej analizy było zweryfikowanie, czy zastosowanie odmiennej implementacji może przyczynić się do dalszej poprawy jakości predykcji.

Ewaluacja modelu LightGBM Classifier z dodatkowymi wektorami dostarczyła następujących rezultatów:

- Dokładność (Accuracy): 0,7744
- Precyzja (Precision): 0,7781
- Czułość (Recall): 0,7842
- Wynik F1 (F1 score): 0,7769

Uzyskane wyniki, choć nadal znacząco lepsze niż w przypadku modeli klasycznych, nie przewyższyły skuteczności modelu XGBoost. Wszystkie wskaźniki jakości predykcji były o około 3-4 punkty procentowe niższe niż w przypadku najlepszego modelu.

Dodatkowo istotnym czynnikiem przemawiającym na niekorzyść modelu LightGBM był znacznie dłuższy czas treningu, wynoszący około 20 minut, ponad dwukrotnie więcej niż w przypadku XGBoost.

5.4 Wnioski

Przeprowadzone badania dostarczyły rozstrzygających dowodów na istotną rolę cech tekstowych, zakodowanych w postaci wektorów właściwościowych, w procesie predykcji sukcesu komercyjnego produkcji filmowych.

W kontekście modeli regresyjnych, włączenie wektorów właściwościowych wygenerowanych na podstawie słów kluczowych oraz krótkich opisów marketingowych dostarczonych przez producentów przyniosło znaczącą poprawę wszystkich analizowanych miar jakości predykcji (tabela 5.1). Model XGBoost Regressor z włączonymi wektorami osiągnął współczynnik determinacji R^2 na poziomie 0,3545, co stanowi znaczącą poprawę względem analogicznego modelu klasycznego (R^2 = 0,1331).

Jeszcze bardziej spektakularne rezultaty uzyskano w kontekście modelowania klasyfikacyjnego (tabela 5.2). Model XGBoost Classifier z wektorami właściwościowymi osiągnął dokładność na poziomie 81,05%, co stanowi niemal dwukrotną poprawę względem klasycznego podejścia (41,03%), taka sama skala poprawy charakteryzowała również pozostałe wskaźniki. Co szczególnie istotne, model z wektorami właściwościowymi wykazał się znacznie większą skutecznością w klasyfikacji klas mniejszościowych, które stanowiły wyzwanie dla modeli bazujących wyłącznie na cechach liczbowych. Analiza SHAP potwierdziła, że największy wkład w decyzje modelu wnoszą właśnie wektory właściwościowe, co dowodzi ich istotnej roli w uchwyceniu niuansów treści filmowych.

W odniesieniu do postawionej hipotezy badawczej H0, uzyskane wyniki jednoznacznie potwierdzają, że modele predykcyjne łączące klasyczne zmienne liczbowe z reprezentacjami wektorowymi tekstu generowanymi na podstawie keywords i overview osiągają statystycznie istotnie lepsze wyniki niż modele wykorzystujące wyłącznie dane liczbowe. Obserwowana poprawa wszystkich analizowanych wskaźników znacząco przekracza przyjęty próg istotności, co przekłada się na brak podstaw do odrzucenia hipotezy H0 na korzyść hipotezy H1.

Tabela 5.1. Porównanie modeli regresji na podstawie uzyskanych miar dobroci

Model	MSE	RMSE	MAE	R^2
LinReg	1,5292	1,2366	0,9654	0,0666
RandomForestRegressor	1,5277	1,2360	0,9647	0,0676
XGBoostRegressor	1,3918	1,1798	0,9207	0,1331
XGBoostRegressor z wektorami właściwościowymi	1,0364	1,0180	0,7994	0,3545

Źródło: Opracowanie własne

Tabela 5.2. Porównanie modeli klasyfikacji na podstawie miar dobroci

Model	Accuracy	Precision	Recall	F1-score
RandomForestClassifier	0,3323	0,3069	0,3137	0,3054
XGBoostClassifier	0,4103	0,3958	0,3928	0,3888
XGBoostClassifier z wektorami właściwościowymi	0,8105	0,8222	0,8196	0,8193
LIghtGBMClassifier z wektorami właściwościowymi	0.7744	0,7781	0,7842	0,7769

Źródło: Opracowanie własne

Podsumowując, przedstawiona metoda łącząca NLP z technikami uczenia maszynowego znacząco podnosi jakość prognozowania zwrotu z inwestycji filmowych, jednocześnie oferując praktyczne narzędzie analityczne. Wyniki te potwierdzają, że uwzględnienie informacji tekstowych jest niezbędne do pełniejszego zrozumienia cech sukcesu kasowego, a opracowany w ramach pracy prototyp stanowi bazę do dalszego rozwoju zarówno na gruncie akademickim, jak i biznesowym.

Rozdział 6

Podsumowanie

Niniejsza praca przedstawia eksperyment porównujący modele klasyczne i uczenia maszynowego, zarówno samodzielne, jak i te rozszerzone o techniki NLP, w kontekście przewidywania sukcesu finansowego produkcji filmowych. W ramach badania stworzono zbiór danych o amerykańskich produkcjach filmowych z lat 2010-2023, pochodzący z API The Movie Database. Dane te obejmowały zarówno zmienne liczbowe, takie jak budżet, przychody czy popularność, jak również zmienne tekstowe w postaci krótkich opisów i słów kluczowych. Przeprowadzona analiza wymagała kompleksowego przygotowania danych, w tym czyszczenia brakujących wartości, transformacji logarytmicznej zmiennych liczbowych oraz przekształcenia zmiennych tekstowych w wektory właściwościowe przy użyciu modelu Qwen3-Embedding-0.6B.

Badanie jednoznacznie potwierdziło hipotezę badawczą, że modele predykcyjne łączące klasyczne zmienne liczbowe z reprezentacjami wektorowymi tekstu osiągają statystycznie istotnie lepsze wyniki niż modele wykorzystujące wyłącznie dane liczbowe. W przypadku modeli regresyjnych, XGBoost Regressor z wektorami właściwościowymi wykazał znaczącą przewagę, osiągając współczynnik determinacji R^2 na poziomie 0,3545 oraz średni błąd bezwzględny MAE równy 0,7994, podczas gdy modele bez cech tekstowych osiągnęły zaledwie $R^2 = 0{,}1331$ oraz MAE = 0,9207. Pomimo znacznego wzrostu skuteczności tych modeli, R^2 na podanym poziomie oznacza, że około 64% wariancji zmiennej zależnej pozostaje niewyjaśnione.

Spektakularną poprawę zaobserwowano w przypadku modeli klasyfikacyjnych, gdzie XGBoost Classifier wzbogacony o wektory właściwościowe uzyskał dokładność na po-

ziomie 81,05% oraz F1-score wynoszący 0,8193, co stanowi niemal dwukrotnie lepszy wynik niż model bez wektorów właściwościowych.

Szczególnie istotnym odkryciem była dominująca rola komponentów pochodzących z wektorów właściwościowych jako najważniejszych cech predykcyjnych, co potwierdziła analiza SHAP. Wynik ten wskazuje na kluczowe znaczenie informacji semantycznych zawartych w opisach fabuły i słowach kluczowych dla prognozowania sukcesu komercyjnego filmu. Rezultaty badania mają istotne znaczenie praktyczne dla przemysłu filmowego, sugerując, że narracja filmowa i inne dane tekstowe mogą skutecznie uzupełnić modele predykcyjne przy szacowaniu sukcesu kasowego.

Dalsze kierunki badań mogłyby obejmować eksplorację dodatkowych źródeł danych niestrukturyzowanych, takich analiza wydźwięku z mediów społecznościowych w okresie premiery. Warto również rozważyć zastosowanie bardziej złożonych architektur modeli językowych, które mogłyby jeszcze lepiej uchwycić niuanse semantyczne i kontekstowe. Ponadto, dalsze badania nad strojeniem modeli mogłyby przyczynić się do poprawy wyników. Rozszerzenie analizy na inne rynki filmowe lub dłuższe okresy czasowe, z uwzględnieniem specyficznych trendów kulturowych jest kolejnym dobrym kierunkiem dalszych badań.

Dalsze doskonalenie modeli hybrydowych łączących zalety danych liczbowych i tekstowych może prowadzić do jeszcze bardziej precyzyjnych prognoz sukcesu komercyjnego produkcji filmowych.

Bibliografia

Alhawiti, K. M. (2014). Natural language processing and its use in education. *International Journal of Advanced Computer Science and Applications*, *5*(12). https://citeseerx.ist.psu.edu/document?repid=rep1&type=pdf&doi=c0e3dd3bcb8990a956db697bd7f5cc26c5390eb0#page=84

Bahja, M. (2020, maj). Natural Language Processing Applications in Business. W *E-Business - Higher Education and Intelligence Applications*. IntechOpen. https://doi.org/10.5772/intechopen.92203

Bakarov, A. (2018, styczeń). *A Survey of Word Embeddings Evaluation Methods* [arXiv:1801.09536 [cs]]. https://doi.org/10.48550/arXiv.1801.09536

Chai, C. P. (2023). Comparison of text preprocessing methods. *Natural Language Engineering*, *29*(3), 509–553. https://doi.org/10.1017/S1351324922000213

Chao, Q., Kim, E., Li, B. (2023). Movie Box Office Prediction With Self-Supervised and Visually Grounded Pretraining [arXiv:2304.10311 [cs]], (arXiv:2304.10311). https://doi.org/10.48550/arXiv.2304.10311

Chowdhary, K. R. (2020). Natural Language Processing. W K. Chowdhary (Red.), *Fundamentals of Artificial Intelligence* (s. 603–649). Springer India. https://doi.org/10.1007/978-81-322-3972-7_19

Christmann, J., Dalon, C., Savioz, Y., Zhou, Y., Gaillard, Q. (2024, grudzień). Data preprocessing [Published on 2024-12-20]. https://epfl-ada.github.io/ada-2024-project-onceuponatimeindata/data_pre_processing/

Dash, G., Sharma, C., Sharma, S. (2023). Sustainable Marketing and the Role of Social Media: An Experimental Study Using Natural Language Processing (NLP). *Sustainability*, *15*(66), 5443. https://doi.org/10.3390/su15065443

Eliashberg, J., Hui, S. K., John Zhang, Z. (2014). Assessing Box Office Performance Using Movie Scripts: A Kernel-Based Approach. *IEEE Transactions on Knowledge and*

Data Engineering, *26*(11), 2639–2648. https://doi.org/10.1109/TKDE.2014.2306681

Goldberg, Y. (2016). A Primer on Neural Network Models for Natural Language Processing. *Journal of Artificial Intelligence Research*, *57*, 345–420. https://doi.org/10.1613/jair.4992

Hirschberg, J., Manning, C. D. (2015). Advances in natural language processing. *Science*, *349*(6245), 261–266. https://doi.org/10.1126/science.aaa8685

Hugging Face. (2025). Massively Multilingual Text Embedding Benchmark (MTEB) Leaderboard [Accessed: 2025-02-14]. https://huggingface.co/spaces/mteb/leaderboard

Kusupati, A., Bhatt, G., Rege, A., Wallingford, M., Sinha, A., Ramanujan, V., Howard-Snyder, W., Chen, K., Kakade, S., Jain, P., Farhadi, A. (2024). Matryoshka Representation Learning [arXiv:2205.13147 [cs]], (arXiv:2205.13147). https://doi.org/10.48550/arXiv.2205.13147

Lee, C., Roy, R., Xu, M., Raiman, J., Shoeybi, M., Catanzaro, B., Ping, W. (2025). NV-Embed: Improved Techniques for Training LLMs as Generalist Embedding Models [arXiv:2405.17428 [cs]]. *arXiv preprint*, *2405.17428*. https://doi.org/10.48550/arXiv.2405.17428

Li, C., Qin, M., Xiao, S., Chen, J., Luo, K., Shao, Y., Lian, D., Liu, Z. (2024). Making Text Embedders Few-Shot Learners [arXiv:2409.15700 [cs]], (arXiv:2409.15700). https://doi.org/10.48550/arXiv.2409.15700

Li, Z., Zhang, X., Zhang, Y., Long, D., Xie, P., Zhang, M. (2023). Towards General Text Embeddings with Multi-stage Contrastive Learning [arXiv:2308.03281 [cs]], (arXiv:2308.03281). https://doi.org/10.48550/arXiv.2308.03281

Luo, H., Macher, J., Wahlen, M. (2020). Judgment Aggregation in Creative Production: Evidence from the Movie Industry. *Harvard Journal*.

Moreira, G. d. S. P., Osmulski, R., Xu, M., Ak, R., Schifferer, B., Oldridge, E. (2024). NV-Retriever: Improving text embedding models with effective hard-negative mining [arXiv:2407.15831 [cs]], (arXiv:2407.15831). https://doi.org/10.48550/arXiv.2407.15831

Mosbach, M. (2023, grudzień). Analyzing Pre-trained and Fine-tuned Language Models. W Y. Elazar, A. Ettinger, N. Kassner, S. Ruder N. A. Smith (Red.), *Proceedings of*

the Big Picture Workshop (s. 123–134). Association for Computational Linguistics. https://doi.org/10.18653/v1/2023.bigpicture-1.10

Muennighoff, N., Tazi, N., Magne, L., Reimers, N. (2023, marzec). *MTEB: Massive Text Embedding Benchmark* [arXiv:2210.07316 [cs]]. https://doi.org/10.48550/arXiv.2210.07316

Mustansir, A., Shahzad, K., Malik, M. K. (2022). Towards automatic business process redesign: an NLP based approach to extract redesign suggestions. *Automated Software Engineering*, *29*(1), 12. https://doi.org/10.1007/s10515-021-00316-8

Osborne, J. D., Wyatt, M., Westfall, A. O., Willig, J., Bethard, S., Gordon, G. (2016). Efficient identification of nationally mandated reportable cancer cases using natural language processing and machine learning. *Journal of the American Medical Informatics Association*, *23*(6), 1077–1084. https://doi.org/10.1093/jamia/ocw006

Parra, X., Tort-Martorell, X., Alvarez-Gomez, F., Ruiz-Viñals, C. (2023). Chronological Evolution of the Information-Driven Decision-Making Process (1950–2020). *Journal of the Knowledge Economy*, *14*(3), 2363–2394. https://doi.org/10.1007/s13132-022-00917-y

Qiu, X., Sun, T., Xu, Y., Shao, Y., Dai, N., Huang, X. (2020). Pre-trained models for natural language processing: A survey. *Science China Technological Sciences*, *63*(10), 1872–1897. https://doi.org/10.1007/s11431-020-1647-3

Sutskever, I. (2024). Sequence to sequence learning with neural networks: what a decade. *Proceedings of the NeurIPS 2024 Conference*. https://openreview.net/group?id=NeurIPS.cc/2024/Conference#tab-accept-oral

Udandarao, V., Gupta, P. (2024). Movie Revenue Prediction using Machine Learning Models [arXiv:2405.11651 [cs]], (arXiv:2405.11651). https://doi.org/10.48550/arXiv.2405.11651

West, R. M. (2022). Best practice in statistics: The use of log transformation. *Annals of Clinical Biochemistry*, *59*(3), 162–165. https://doi.org/10.1177/00045632211050531

Young, T., Hazarika, D., Poria, S., Cambria, E. (2018). Recent Trends in Deep Learning Based Natural Language Processing [Review Article]. *IEEE Computational Intel-*

ligence Magazine, *13*(3), 55–75. https://doi.org/10.1109/MCI.2018.2840738

Zhang, Z., Meng, Y., Xiao, D. (2024). Prediction techniques of movie box office using neural networks and emotional mining. *Scientific Reports*, *14*(1), 21209. https://doi.org/10.1038/s41598-024-72340-z

Spis tabel

4.1 Rozkład zebranych filmów, pogrupowany latami 25
4.2 Opis kolumn w zbiorze danych filmów 26
4.3 Dziesięć najczęstszych słów kluczowych 38

5.1 Porównanie modeli regresji na podstawie uzyskanych miar dobroci . . . 56
5.2 Porównanie modeli klasyfikacji na podstawie miar dobroci 56

Spis rysunków

4.1 Wartości odstające dla kolumny budget 28
4.2 Wartości odstające dla kolumny revenue 28
4.3 Wartości odstające dla kolumny popularity 28
4.4 Wartości odstające dla kolumny runtime 29
4.5 Budżet a przychód 29
4.6 Logarytm z budżetu a logarytm z przychodu 30
4.7 Popularność a przychód 31
4.8 Rozkład zmiennej budget 31
4.9 Rozkład zmiennej revenue 32
4.10 Rozkład zmiennej popularity 32
4.11 Rozkład zmiennej log budget 33
4.12 Rozkład zmiennej log revenue 34
4.13 Rozkład zmiennej log popularity 34
4.14 Rozkład zmiennej docelowej 35

5.1 Wizualizacja klastrów przypisanych poprzez K-means (Overview) 44
5.2 Wizualizacja klastrów przypisanych poprzez K-means (Keywords) 45
5.3 Macierz pomyłek dla modelu Random Forest Classifier 48
5.4 Macierz pomyłek dla modelu XGBoost Classifier bez wektorów właściwościowych 51
5.5 Macierz pomyłek dla modelu XGBoost Classifier z wykorzystaniem wektorów właściwościowych 53

Spis kodów źródłowych

4.1 Kod obliczający IQR 27